

**Pour une Rationalisation Atomique
de la Graphie Créole Haïtienne**

MÉMOIRE DE RECHERCHE

Pour une Rationalisation Atomique de la Graphie Créole Haïtienne

De la Réforme Orthographique de 1979 à l'Alphabet Atomique Créole (AAC)

*Normalisation numérique, économie graphématique et souveraineté linguistique à l'ère de l'intelligence
artificielle*

Haricot Lincoln Compère

Ingénieur en informatique

Haïti · 2026

© 2026, Haricot Lincoln Compère. Tous droits réservés.

Pour une Rationalisation Atomique de la Graphie Créole Haïtienne — De la Réforme Orthographique de 1979 à l'Alphabet Atomique Créole (AAC).

Première édition, juillet 2026.

ISBN : [en attente de l'obtention de l'ISBN auprès de la Bibliothèque Nationale d'Haïti]

Dépôt légal : Bibliothèque Nationale d'Haïti, [en attente].

Aucune partie de cet ouvrage ne peut être reproduite, distribuée ou transmise sous quelque forme ou par quelque moyen que ce soit, y compris la photocopie, l'enregistrement ou toute autre méthode électronique ou mécanique, sans l'autorisation écrite préalable de l'auteur, sauf dans le cas de courtes citations incluses dans des articles critiques ou des analyses non commerciales, conformément aux usages académiques.

Le code source du convertisseur orthographique et de la démonstration technique associée à cet ouvrage est distribué séparément sous licence libre MIT.

Composé en Garamond. Mise en page réalisée par l'auteur.

Imprimé en Haïti / impression à la demande.

À mon épouse, Darnide E. Compère, pour sa patience infinie, son amour et sa présence constante à mes côtés tout au long de ce projet de recherche.



À ma fille, Asbaëlle Darma. L. Compère, pour la promesse d'avenir qu'elle incarne. Que cet ouvrage l'inspire à toujours poursuivre la clarté et le savoir.



À mes parents, Anouse St. Compère et Lincoln Compère, qui m'ont transmis la beauté profonde de notre langue maternelle et m'ont inculqué, par leurs innombrables sacrifices, la rigueur et la valeur de l'instruction scientifique.



À mes professeurs, repères indispensables de mon parcours universitaire.



À la République d'Haïti, à sa terre historique et à ses millions de locuteurs à travers le monde. Que cette modélisation atomique de l'Alphabet Atomique Créole soit une humble pierre posée sur le chemin de notre souveraineté technologique, afin que notre langue nationale s'impose avec force, précision et dignité à l'ère de l'intelligence artificielle et de la mondialisation numérique.

Avant-propos

Ce livre est né d'un agacement technique, avant d'être une thèse. Comme des milliers d'ingénieurs et de développeurs créolophones, j'ai passé des années à taper du texte sur des interfaces conçues sans que jamais personne ne se demande combien de gestes, combien de caractères, combien de bande passante coûtait chaque digramme hérité d'un système pensé pour le papier plutôt que pour l'écran. Ce livre est ma tentative de répondre à cette question avec la rigueur qu'elle mérite, et de la poser à qui de droit : l'Académie du Créole Haïtien, gardienne légitime de la norme orthographique de notre langue.

Je ne suis pas linguiste de formation, et ce livre ne prétend pas se substituer à l'expertise de ceux qui le sont. Il propose, documente et chiffre. Il part d'un principe simple, presque naïf à énoncer : une lettre devrait représenter un son, et un son ne devrait avoir besoin que d'une lettre. Ce principe, l'orthographe officielle de 1979 l'a affirmé avec courage et l'a appliqué avec une rigueur remarquable pour son époque. Ce livre ne cherche qu'à en achever la promesse, avec les outils qu'un ingénieur du vingt-et-unième siècle a en main et que les linguistes de 1979 n'avaient pas encore : Unicode, le traitement automatique du langage, et une capacité de calcul qui permet aujourd'hui de mesurer, caractère par caractère, ce qu'une réforme graphématique change réellement.

Ce texte a d'abord existé sous la forme d'un mémoire de recherche indépendant, soumis à l'Académie du Créole Haïtien — le terme est employé ici dans son sens classique d'exposé raisonné soumis au jugement d'une académie savante, non dans son acception universitaire contemporaine : ce travail n'a bénéficié d'aucun encadrement académique formel, et ne prétend à aucune validation institutionnelle qu'il n'a pas reçue. Cette édition en reprend l'intégralité du contenu scientifique (diagnostic, proposition, protocole d'implémentation, évaluation d'impact), dans une forme destinée à un lectorat plus large que celui d'un jury académique : quiconque s'intéresse à l'avenir écrit du créole haïtien, qu'il soit enseignant, développeur, parent, ou simplement curieux de la façon dont une langue peut se réinventer sans se renier.

Puisse ce livre contribuer, à sa modeste mesure, à ce qu'un jour, écrire correctement sa langue maternelle en créole coûte un geste de moins à chaque enfant haïtien qui apprend à lire.

Haricot Lincoln Compère

Table des matières

Avant-propos	v
Table des matières.....	vii
Introduction générale	1
Contexte et justification de l'étude	1
Énoncé de la problématique	3
Questions et hypothèses de recherche.....	4
Objectifs du mémoire	5
Méthodologie et corpus de la recherche	6
Chapitre I — Évolution historique et état des lieux de la graphie créole (de la genèse à la réforme de 1979).....	9
1.1 Les premières tentatives de transcription : de la période coloniale à l'indépendance	9
1.2 La guerre des graphies au XXe siècle : de la méthode phonétique à la méthode systématique	11
1.2.1 <i>Le système McConnell-Laubach (1940)</i>	11
1.2.2 <i>Le système Pressoir-Faublas (1947)</i>	12
1.3 La consécration de la réforme officielle du 28 septembre 1979	13
1.4 Comparaisons internationales : les réformes graphématiques dans le monde	14
Chapitre II — Diagnostic critique : les limites technologiques et pédagogiques de la graphie actuelle	17
2.1 L'anomalie des digrammes et trigrammes	17
2.2 L'obstacle de l'ambiguïté algorithmique	19
2.3 Le cas de la voyelle fantôme u : anomalie phonologique de la séquence ui	20
2.4 L'inflation nominale de l'inventaire alphabétique.....	22

Chapitre III — Proposition d'une réforme intégrale et protocole de normalisation numérique	25
3.1 Présentation du nouvel alphabet atomique.....	26
3.1.1 <i>Qu'est-ce qu'un alphabet atomique ?</i>	26
3.1.2 <i>Les voyelles accentuées : combinaisons, non nouvelles lettres</i>	27
3.1.3 <i>Une conséquence bienvenue : la disparition de la lettre h</i>	29
3.1.4 <i>L'inventaire des vingt-quatre lettres atomiques</i>	30
3.1.5 <i>Comparaison des inventaires alphabétiques nominaux</i>	31
<i>Note officielle sur le statut des semi-voyelles W et Y</i>	34
<i>Tableau comparatif des trois systèmes graphiques</i>	34
3.2 Théorisation de la combinaison phonotactique et diacritique.....	36
<i>Démonstration lexicale : de la théorie aux mots réels</i>	40
3.3 Guide d'implémentation technologique	40
3.3.1 <i>Standardisation des claviers physiques et virtuels</i> ..	41
3.3.2 <i>Encodage Unicode et normalisation ISO</i>	42
3.3.3 <i>Entraînement des modèles d'intelligence artificielle</i>	42
3.3.4 <i>Feuille de route de déploiement en quatre phases</i>	43
3.4 Alternatives envisagées et raisons de leur écartement..	45
3.4.1 <i>La ligature géométrique êh pour le son /f/</i>	45
3.4.2 <i>Le tilde de nasalité pour an, en et on</i>	47
3.4.3 <i>Pourquoi pas un monogramme d'inspiration africaine ?</i>	48
<i>Première catégorie : des digrammes, pas des monogrammes</i>	49

<i>Deuxième catégorie : un phonème absent des langues du substrat</i>	49
<i>Troisième catégorie : un vrai monogramme, mais une leçon involontaire</i>	50
3.5 Tableau comparatif des alphabets atomiques du créole haïtien postérieurs à 1979	52
3.6 L'AAC et la grammaire créole : une réforme strictement de graphèmes	56
Chapitre IV — Évaluation des impacts : gains économiques, sociaux et accélération de l'apprentissage	59
4.1 Analyse quantitative du gain scriptural	59
4.1.1 Exemples d'application directe.....	59
4.1.2 Étude de corpus : l'extrait de René Depestre	61
4.1.3 Projection à grande échelle : impact éditorial et écologique.....	62
4.2 Impact psycholinguistique et didactique	64
4.2.1 Le principe d'automatisme de la lecture.....	64
4.2.2 Le tracé continu et la mémoire motrice scolaire	65
4.2.3 Trois substitutions ciblées : mémorisation minimale	66
4.2.4 Arguments industriels et numériques complémentaires.....	67
4.3 Viabilité et coût de transition	68
4.4 Discussion critique : objections anticipées et éléments de réponse.....	70
4.4.1 « Le système de 1979 fonctionne déjà : pourquoi le modifier ? »	70
4.4.2 « Le gain scriptural mesuré (9 à 13 %) est plus modeste que dans les versions antérieures de la réforme : celle-ci reste-t-elle justifiée ? »	71

4.4.3 « Pourquoi ne pas être allé plus loin en simplifiant également an, en et on ? »	71
4.4.4 « L'usage de diacritiques tels que le caron et la brève complique la frappe rapide sur clavier mobile » ...	72
4.4.5 « Le décompte de vingt-quatre lettres n'est-il qu'un artifice rhétorique, puisque à, è, ò, an, en et on continuent de s'écrire exactement comme avant ? »	73
Chapitre V — Intelligence artificielle et traitement automatique du créole : la tokenisation à l'ère des grands modèles de langage	75
5.1 Comprendre la tokenisation : comment un modèle de langage « lit » un texte	75
5.2 Pourquoi les digrammes créoles interfèrent avec les modèles entraînés majoritairement sur le français	77
5.3 Un problème documenté à l'échelle des langues à faibles ressources	78
5.4 Tableau comparatif face au défi de la tokenisation	79
5.5 Ce qui change à court terme, ce qui change à long terme	80
5.6 Protocole de mise en œuvre : comment obtenir une tokenisation optimale pour l'AAC	81
5.7 Bénéfices attendus	83
Conclusion générale	85
Synthèse des résultats majeurs	85
Limites de la recherche et perspectives d'avenir	88
Références bibliographiques	93
Annexe — Glossaire des termes techniques	95
Annexe — Inventaire phonologique complet en Alphabet Phonétique International	99
Voyelles	100
Consonnes	101

Semi-voyelles et séquence particulière	102
Index — Les vingt-quatre lettres atomiques de l'AAC et leurs codepoints Unicode	103
Index thématique — Navigation par concept	105
Synthèse finale — Le créole face aux grandes langues internationales	107
À propos de l'auteur	109

Introduction générale

***Note liminaire sur le terme « mémoire ».** Ce document porte le nom de mémoire — Il ne le désigne pas tel qu'on le comprend aujourd'hui dans le cadre universitaire contemporain, qui suppose d'avoir un directeur, un jury et d'un suivi académique, mais dans son sens classique et plus ancien : un exposé écrit et raisonné, soumis au jugement d'une académie savante. Ce modèle des mémoires ressemble à ceux que les chercheurs, ingénieurs et savants non affiliés à une université ont adressés depuis plusieurs siècles aux académies des sciences. Ce document n'a fait l'objet d'aucune supervision académique formelle et ne prétend à aucune validation institutionnelle qu'il n'a pas reçue ; il est très précisément ce que son titre indique : un exposé soumis à l'examen de l'Académie du Créole Haïtien.*

Contexte et justification de l'étude

La langue est un système dynamique qui évolue au rythme des transformations de la société qui la parle. Le créole haïtien, langue nationale d'Haïti et ciment identitaire d'une diaspora transnationale de plusieurs millions de locuteurs, a connu son acte de naissance institutionnel avec la réforme orthographique officielle du 28 septembre 1979. Cette réforme, historique à plus d'un titre, a permis de sortir la langue de l'anarchie graphique héritée de trois siècles de transcriptions empruntées sans méthode au français, en adoptant un principe phonologique fort et unificateur : à chaque son du créole correspond une lettre ou un groupe de lettres fixe et prévisible.

Près d'un demi-siècle plus tard, le contexte mondial dans lequel évolue la langue créole a radicalement changé. L'avènement de l'Internet, la mondialisation des échanges culturels et économiques,

la miniaturisation des interfaces de saisie mobile et, plus récemment, l'explosion de l'intelligence artificielle et du traitement automatique du langage naturel (TALN) imposent aux systèmes d'écriture des contraintes techniques nouvelles que les rédacteurs de la graphie de 1979 ne pouvaient ni anticiper ni intégrer à leur réflexion. Ce mémoire part du constat que l'alphabet officiel du créole haïtien, tout en demeurant un acquis institutionnel irremplaçable, présente aujourd'hui des marges de perfectionnement technique significatives à la lumière des standards internationaux de normalisation des écritures.

Conçue initialement pour une écriture manuscrite et une impression sur support papier, l'orthographe officielle du créole haïtien souffre aujourd'hui de lourdeurs graphématiques identifiables et mesurables. L'utilisation de digrammes et de trigrammes, tels que : ch, ng, an, en, on, ou et oun, sature l'alphabet de base de combinaisons de lettres qui pourraient, en toute rigueur phonologique, être gérées de manière atomique par des monogrammes dédiés, à l'instar de langues internationales de diffusion comparable comme le roumain, le turc ou le vietnamien. De plus, la persistance de structures graphiques héritées de l'étymologie française, telles que l'emploi du digramme ui alors que la voyelle u n'existe pas de façon autonome dans le système phonologique créole, crée des anomalies à la fois pédagogiques pour l'apprenant et computationnelles pour les systèmes de traitement automatique de la langue.

À l'ère du traitement automatique du langage naturel et de l'intégration numérique globale, ces redondances graphématiques freinent l'efficacité technique de la langue écrite : elles augmentent le coût de stockage des données en octets, ralentissent la vitesse de frappe sur les interfaces mobiles, complexifient la segmentation lexicale pour les moteurs de traduction automatique et surchargent inutilement la mémoire cognitive des apprenants au moment critique de l'alphabétisation initiale. C'est cette conjonction d'un acquis institutionnel à préserver et d'un potentiel d'optimisation technique à réaliser qui constitue la justification première de la présente recherche.

Énoncé de la problématique

Dès lors, face à l'urgence d'une normalisation à la fois internationale et numérique de la graphie créole, ce mémoire pose la problématique suivante :

Dans quelle mesure une refonte rationalisée et atomique de l'alphabet du créole haïtien — par l'introduction de monogrammes standardisés, l'élimination des digrammes vocaliques redondants et l'harmonisation des semi-voyelles — peut-elle optimiser les performances technologiques, économiques et pédagogiques de la langue à l'ère de la mondialisation numérique, sans rompre la continuité institutionnelle établie par le décret de 1979 ?

Cette problématique centrale se décline en une interrogation subsidiaire, de nature méthodologique et politique : une réforme graphématique de cette nature peut-elle être conçue non comme une

rupture avec l'acquis de 1979, mais comme son achèvement logique — c'est-à-dire comme la réalisation intégrale de la promesse fondatrice d'un système à bi-univocité totale, où chaque son du créole correspond à un seul et unique graphème, que les outils typographiques et informatiques de 1979 ne permettaient pas encore de tenir dans son entièreté ?

Questions et hypothèses de recherche

La recherche s'organise autour de trois questions spécifiques, auxquelles correspondent trois hypothèses de travail :

- Question 1 : Dans quelle mesure les digrammes et trigrammes de l'orthographe de 1979 constituent-ils une entorse mesurable au principe phonologique fondateur de la réforme, et quelles en sont les conséquences documentées dans l'enseignement primaire et le traitement informatique de la langue ? Hypothèse H1 : la présence de six séquences polygraphiques pour des phonèmes uniques crée une surcharge cognitive quantifiable chez l'apprenant et une ambiguïté structurelle mesurable dans les algorithmes de segmentation lexicale.
- Question 2 : Est-il possible de concevoir un alphabet atomique de substitution qui élimine ces redondances tout en demeurant rétrocompatible, c'est-à-dire immédiatement déchiffrable par un lecteur déjà formé à l'orthographe de 1979, et peut-être encodé dans les standards Unicode

contemporains ? Hypothèse H2 : un jeu restreint de graphèmes monogrammatiques déjà standardisés (monogramme š, brève de fermeture ǒ, eng ɳ), ciblant exclusivement les séquences phonologiquement opaques et laissant inchangées les séquences déjà transparentes telles que an, en et on satisfait simultanément aux critères de lisibilité, de faisabilité technique immédiate et de continuité pédagogique.

- Question 3 — Quels gains économiques, sociaux et pédagogiques peut-on raisonnablement attendre d'une telle réforme, et à quelles conditions de transition ces gains peuvent-ils être atteints sans rupture culturelle avec le corpus littéraire et documentaire existant ? Hypothèse H3 : la réduction du nombre de caractères par unité de texte, de l'ordre de 9 à 13 % selon le type de document, génère des économies mesurables en matière d'impression, de bande passante, de charge serveur et de temps d'apprentissage, pour un coût de transition rendu quasi nul par le choix délibéré de graphèmes déjà standardisés.

Objectifs du mémoire

Pour répondre à cette problématique, la présente recherche poursuit un triple objectif, décliné selon trois axes complémentaires :

- Un objectif historique : retracer et analyser la trajectoire évolutive de la graphie créole, depuis les premières tentatives

de transcription de l'époque coloniale jusqu'à la consécration de la réforme officielle de 1979, afin de situer la présente proposition dans une continuité institutionnelle et scientifique plutôt que dans une rupture.

- Un objectif technique : concevoir, documenter et justifier un modèle d'alphabet atomique allégé, entièrement encodable dans les standards Unicode contemporains, respectueux des acquis phonologiques du décret de 1979 et immédiatement opérationnel pour les claviers virtuels, les moteurs de traitement automatique du langage et l'entraînement des grands modèles de langage.
- Un objectif pragmatique : évaluer, à l'aide de données quantitatives issues d'un corpus littéraire de référence et de projections à l'échelle éditoriale nationale, les gains économiques, écologiques et pédagogiques susceptibles de résulter de cette réforme, ainsi que les conditions méthodologiques d'une transition maîtrisée.

Méthodologie et corpus de la recherche

La méthodologie retenue pour ce mémoire est de nature qualitative et comparative, articulée autour de trois démarches complémentaires. La première est une démarche historiographique, fondée sur l'étude des textes fondateurs de la normalisation créole — décret du 28 septembre 1979, travaux de la commission linguistique dirigée par le professeur Pierre Vernet, systèmes antérieurs de McConnell-Laubach et de Pressoir-Faublas — replacés

dans leur contexte institutionnel et comparés, lorsque cela est pertinent, à des réformes orthographiques menées dans d'autres aires linguistiques.

La deuxième démarche est une démarche linguistique descriptive et contrastive, consistant à établir, phonème par phonème, l'inventaire exhaustif des divergences entre la notation officielle de 1979 et la proposition de l'Alphabet Atomique Créole, en s'appuyant sur la transcription phonétique en alphabet phonétique international pour garantir la rigueur scientifique de la comparaison, quel que soit le système graphique considéré.

La troisième démarche, enfin, est une démarche quantitative appliquée à un corpus contrôlé : l'analyse comparée d'un extrait littéraire de référence, choisi pour sa représentativité phonologique, transcrit successivement dans les deux systèmes et soumis à un décompte rigoureux du nombre de caractères, avec et sans les espaces, permettant de mesurer objectivement le gain scriptural revendiqué et d'en établir une projection raisonnée à l'échelle de l'édition scolaire nationale. Les limites inhérentes à cette méthodologie — en particulier la taille restreinte du corpus quantitatif retenu — sont discutées de façon transparente en conclusion générale, section consacrée aux limites de la recherche.

Ces trois objectifs structurent l'architecture du présent mémoire. Le premier chapitre établit le socle historique indispensable à la compréhension de l'enjeu. Le deuxième chapitre pose un diagnostic

critique et documenté des limites de la graphie actuelle. Le troisième chapitre expose la proposition de réforme elle-même, l'Alphabet Atomique Créole, dans le détail de sa conception linguistique et de son implémentation technique. Le quatrième chapitre en évalue les impacts prévisibles sur le plan économique, social et pédagogique. Le cinquième chapitre, enfin, approfondit un enjeu contemporain spécifique, celui du traitement automatique du créole par les grands modèles de langage. La conclusion générale synthétise les résultats et ouvre sur les perspectives de mise en œuvre institutionnelle auprès de l'Académie du Créole Haïtien.

Chapitre I — Évolution historique et état des lieux de la graphie créole (de la genèse à la réforme de 1979)

Comprendre la pertinence d'une réforme graphématique contemporaine suppose au préalable de retracer la trajectoire longue et heurtée de l'écriture du créole haïtien. Loin d'être un caprice technocratique récent, la question de la meilleure façon de transcrire les sons du créole traverse près de deux siècles et demi d'histoire linguistique haïtienne, depuis les balbutiements de la période coloniale jusqu'à la consécration institutionnelle de 1979. Ce chapitre retrace cette évolution en trois temps : les premières tentatives de transcription antérieures à toute codification scientifique, la période de compétition entre systèmes concurrents au XXe siècle, puis la réforme officielle de 1979 qui demeure, à ce jour, la norme en vigueur.

1.1 Les premières tentatives de transcription : de la période coloniale à l'indépendance

Le créole haïtien est né du choc violent et irréversible entre plusieurs familles linguistiques africaines — principalement le fon, l'ewé, le wolof et le kikongo — et le français des colons de Saint-Domingue aux XVIIe et XVIIIe siècles. Dans les plantations de la colonie la plus productive du monde occidental de l'époque, la nécessité de communiquer entre esclaves de langues différentes, ainsi qu'avec les colons, a engendré en moins de deux générations une

langue entièrement nouvelle : stable, structurée grammaticalement, dotée d'un lexique et d'une syntaxe propres, distincte tant des langues africaines d'origine que du français dont elle a puisé une large part de son vocabulaire.

Aujourd'hui parlé par plus de onze millions de personnes en Haïti et dans sa diaspora mondiale, le kreyòl est la langue maternelle de la quasi-totalité de la population haïtienne et l'une des deux langues officielles de la République depuis la Constitution de 1987. Pourtant, pendant près de trois siècles, cette langue d'une remarquable cohérence phonologique interne est restée essentiellement orale. Les rares tentatives d'écriture du créole durant la période coloniale et postrévolutionnaire empruntaient sans méthode systématique les conventions orthographiques du français — une langue dont la relation entre sons et graphèmes est notoirement opaque et irrégulière — produisant des transcriptions anarchiques, fluctuantes d'un scripteur à l'autre, et par construction inaccessibles à quiconque n'avait pas déjà acquis une maîtrise du français écrit.

Cette situation engendre un paradoxe fondateur qui pèsera sur toute l'histoire ultérieure de la graphie créole : le créole parlé était la langue du peuple haïtien dans toute sa richesse expressive et son universalité sociale, tandis que le créole écrit, quand il existait, restait une approximation phonétisée du français, réservée à une élite lettrée déjà bilingue. L'écriture, loin de démocratiser l'accès à la langue

nationale, en reproduisait au contraire les hiérarchies sociales héritées de la colonisation. C'est cette contradiction que les réformateurs du XXe siècle chercheront à résoudre.

1.2 La guerre des graphies au XXe siècle : de la méthode phonétique à la méthode systématique

1.2.1 Le système McConnell-Laubach (1940)

En 1940, les missionnaires protestants Harold McConnell et Frank Laubach publient le premier système graphique véritablement cohérent pour le créole haïtien. Leur approche est résolument phonétique : chaque son de la langue reçoit un symbole unique et invariable, indépendamment de l'étymologie française du mot dont il est issu. C'est une révolution conceptuelle pour l'époque, en rupture radicale avec les habitudes de transcription francisante héritées du XIXe siècle. Pour la première fois, un citoyen haïtien non scolarisé en français pouvait apprendre à lire sa propre langue maternelle en quelques semaines, sans passer par le filtre réducteur et excluant du français écrit.

Le système McConnell-Laubach adopte des conventions vocaliques proches de l'espagnol et du latin, et marque la nasalité par des digrammes en *n* suffixé — une solution pragmatique mais qui introduira, on le verra, une source persistante de digraphie dans tous les systèmes qui lui succéderont, y compris la norme de 1979 et, par extension, le problème central que le présent mémoire se propose de résoudre.

1.2.2 Le système Pressoir-Faublas (1947)

En 1947, l'écrivain et linguiste haïtien Charles Fernand Pressoir publie, en collaboration avec J. J. Faublas, un système révisé qui affine la transcription des voyelles, stabilise la notation des consonnes et introduit une représentation plus systématique des tons et des voyelles nasales que ne le faisait le système McConnell-Laubach. Ce système servira de base de discussion pour les décennies suivantes et inspirera directement les travaux ultérieurs de la commission de normalisation qui aboutira à la réforme de 1979.

Cependant, ni le système McConnell-Laubach ni le système Pressoir-Faublas ne parviennent, chacun pris isolément, à s'imposer comme standard national unique au cours des trois décennies suivantes. Les institutions scolaires, les organisations religieuses et les publications de l'époque continuent d'adopter des orthographe divergentes, parfois de manière concurrente au sein d'une même région, créant une fragmentation graphique préjudiciable à l'unification culturelle et éducative du pays. Cette période, que l'on peut à juste titre qualifier de « guerre des graphies », illustre combien la question orthographique du créole a toujours été, au-delà de sa dimension strictement linguistique, une question éminemment politique et institutionnelle.

1.3 La consécration de la réforme officielle du 28 septembre 1979

Le 28 septembre 1979, le ministère de l'Éducation Nationale d'Haïti, sous l'autorité du Secrétaire d'État Joseph C. Bernard, promulgue un décret instituant l'alphabet officiel du créole haïtien. Fruit d'années de travail d'une commission linguistique dirigée notamment par le professeur Pierre Vernet et ses collègues linguistes, cet alphabet établit un système strictement phonologique d'une trentaine de graphèmes de base : chaque son distinct du créole y est représenté par un et un seul symbole, et réciproquement chaque symbole ne représente qu'un et un seul son. C'est cette norme, dite orthographe officielle de 1979, qui demeure en vigueur à ce jour et qui sert de référence à l'ensemble du présent mémoire.

Ce décret constitue un acte de souveraineté culturelle majeur dans l'histoire haïtienne contemporaine. Il brise l'hégémonie de l'orthographe française sur l'écrit créole, ouvre juridiquement et pédagogiquement la voie à une éducation véritablement bilingue, et pose les fondations d'une alphabétisation de masse fondée sur la langue réellement parlée par la population plutôt que sur une langue seconde. Les statistiques d'alphabétisation s'améliorent significativement dans les années qui suivent sa mise en application progressive dans le système éducatif national, confirmant empiriquement la pertinence du choix d'une orthographe phonologique proche de la prononciation réelle.

Le rôle de l'Académie du Créole Haïtien — Akademi Kreyòl Ayisyen, instituée plus tardivement par la loi du 6 avril 2014 comme organe scientifique de régulation, de promotion et de normalisation de la langue créole — s'inscrit directement dans la continuité de cet acte fondateur de 1979. C'est à cette même institution que le présent mémoire soumet sa proposition de perfectionnement graphématique, dans un esprit de continuité et non de rupture.

1.4 Comparaisons internationales : les réformes graphématiques dans le monde

L'idée qu'un système d'écriture puisse être révisé, y compris longtemps après son adoption officielle, pour l'ajuster aux besoins nouveaux de la société qui le pratique n'est nullement une singularité haïtienne. Elle s'inscrit au contraire dans une tradition internationale bien documentée de réformes orthographiques délibérées, dont trois exemples éclairent utilement la démarche du présent mémoire.

La réforme kémaliste de l'alphabet turc, en 1928, demeure l'exemple le plus radical de rupture graphématique planifiée : en l'espace de quelques semaines, la République de Turquie remplace l'alphabet arabo-persan, mal adapté à la phonologie turque, par un alphabet latin augmenté de lettres spécifiques telles que *ı*, *ğ* ou *ş* — cette dernière n'étant pas sans évoquer, par sa fonction phonétique de sifflante et par son diacritique en cédille apparenté au caron, le monogramme *ś* retenu par l'AAC pour le son /ʃ/ du créole. Cette réforme, bien que considérablement plus large dans son ampleur que

celle proposée ici, démontre qu'un changement graphématique majeur peut être mené à bien en un temps très court dès lors qu'existe une volonté politique claire et un accompagnement pédagogique massif.

La réforme norvégienne, engagée dès 1938 et poursuivie jusqu'en 1972, offre un contre-exemple instructif : celui d'une unification graduelle et prudente entre deux normes concurrentes du norvégien écrit, le bokmål et le nynorsk, menée par étapes successives sur plusieurs décennies afin de ménager les sensibilités régionales et de laisser le temps à chaque génération scolaire de s'approprier les évolutions. Cette approche progressive, par paliers négociés plutôt que par rupture unique, est directement comparable à la stratégie de déploiement en quatre phases retenue pour l'AAC au chapitre III du présent mémoire.

Le système du chữ Quốc ngữ vietnamien, enfin, constitue un précédent particulièrement pertinent sur le plan strictement typographique : la transcription romanisée du vietnamien, aujourd'hui seule norme d'écriture officielle du pays, repose massivement sur l'emploi de diacritiques superposés aux voyelles de base pour noter à la fois le timbre vocalique et le ton lexical, exactement selon le principe de combinaison diacritique retenu par l'AAC pour la notation de la nasalité créole. Le succès et la stabilité de ce système sur près d'un siècle démontrent la viabilité à long terme

d'une architecture graphématique fondée sur l'empilement contrôlé de diacritiques plutôt que sur la multiplication de lettres pleines.

Ces trois précédents ne sont pas convoqués pour suggérer une équivalence d'ampleur avec la présente proposition — l'AAC, on l'a souligné, ne touche qu'à quatre séquences opaques résiduelles et préserve intégralement la structure phonologique et grammaticale du créole, y compris les séquences nasales déjà transparentes — mais pour établir que la démarche de perfectionnement graphématique engagée par ce mémoire s'inscrit dans une pratique internationale éprouvée, documentée et, dans plusieurs cas cités, couronnée de succès durable.

CONSTAT DE TRANSITION — Malgré son excellence conceptuelle et son ambition phonologique affirmée, l'alphabet de 1979 a hérité d'une imperfection structurelle que ses concepteurs n'avaient ni le loisir théorique ni les outils technologiques de résoudre entièrement à l'époque : la présence résiduelle de digrammes et de trigrammes pour des sons pourtant élémentaires et fréquents de la langue. C'est précisément ce constat, développé et documenté au chapitre suivant, qui fonde la problématique du présent mémoire.

Chapitre II — Diagnostic critique : les limites technologiques et pédagogiques de la graphie actuelle

Le premier chapitre a établi la légitimité historique et institutionnelle incontestable de la réforme de 1979. Le présent chapitre en propose un examen critique, non pour en contester la valeur fondatrice, mais pour en identifier précisément les limites structurelles qui, un demi-siècle plus tard, freinent l'optimisation technologique et pédagogique de la langue créole. Ce diagnostic s'organise en quatre temps : l'anomalie que constituent les digrammes et trigrammes au regard du principe phonologique fondateur, l'obstacle que ces mêmes séquences opposent au traitement automatique du langage, le cas particulier, emblématique, de la voyelle fantôme u, et l'inflation nominale d'un inventaire alphabétique qui confond lettres irréductibles et lettres combinées.

2.1 L'anomalie des digrammes et trigrammes

Un digramme est, par définition linguistique, une séquence de deux lettres encodant un son unique et indivisible ; un trigramme, une séquence de trois lettres pour le même type de fonction. L'alphabet créole de 1979, dans sa très grande majorité rigoureusement phonologique, comporte néanmoins plusieurs digrammes fonctionnels qui font exception à son principe fondateur : ch pour le son /ʃ / (fricative post-alvéolaire sourde), ou pour /u/ (voyelle fermée arrondie postérieure), an pour /ã/ (voyelle nasale

centrale), en pour /ẽ/ (voyelle nasale antérieure), on pour /õ/ (voyelle nasale postérieure), et ng pour /ɲ/ (consonne nasale palatale). Le son /ũ/ est quant à lui représenté par le trigramme ouñ — trois lettres pour un seul phonème.

Le paradoxe ainsi mis au jour est scientifiquement documentable et documenté : un alphabet proclamé phonologique, dont l'ambition fondatrice et la promesse institutionnelle explicite sont formulées selon le principe « un son, un symbole », continue en pratique d'utiliser deux, voire trois symboles graphiques pour encoder des sons parfaitement élémentaires et statistiquement très fréquents de la langue créole. Ce paradoxe n'est pas une curiosité théorique sans portée pratique. Il a des conséquences mesurables dans l'enseignement primaire, dans l'édition scolaire, dans le traitement informatique automatique de la langue, et dans l'affichage numérique industriel — quatre domaines que ce mémoire documente successivement aux chapitres III et IV.

À titre de comparaison internationale, il est éclairant de noter que l'alphabet finnois, le roumain, le turc après la réforme kémaliste de l'alphabet de 1928, ou le swahili standardisé — toutes langues à orthographe phonologique revendiquée et comparable en ambition à celle du créole de 1979 — comportent peu ou pas de digrammes fonctionnels équivalents. Le créole haïtien dispose aujourd'hui de toutes les conditions historiques, institutionnelles et technologiques réunies pour achever ce travail de normalisation entamé en 1979 :

une académie linguistique établie et légalement mandatée, une communauté scientifique engagée et disponible, et des outils typographiques et informatiques numériques qui, précisément, n'existaient pas au moment de la rédaction du décret original.

2.2 L'obstacle de l'ambiguïté algorithmique

Au-delà de sa dimension pédagogique, la présence de digrammes fonctionnels dans l'alphabet créole pose un problème spécifique et documenté aux systèmes de traitement automatique du langage naturel. En traitement de texte informatique, la longueur des chaînes de caractères impacte directement l'allocation de mémoire tampon, les performances des algorithmes d'indexation et de recherche textuelle, ainsi que la largeur des champs dans les bases de données relationnelles. Mais le problème le plus sérieux n'est pas quantitatif : il est qualitatif et structurel.

L'utilisation de digrammes introduit en effet des ambiguïtés structurelles dans les algorithmes de segmentation lexicale, dite tokenisation, employés par les moteurs de traduction automatique, les correcteurs orthographiques et les systèmes de synthèse et de reconnaissance vocale. Un exemple canonique illustre cette difficulté : un moteur de traitement automatique du créole doit, à chaque occurrence de la séquence de lettres *ou*, résoudre une ambiguïté référentielle non triviale — s'agit-il du digramme phonologique représentant la voyelle fermée /u/ à l'intérieur d'un mot, ou bien de la conjonction de coordination indépendante *ou*, homonyme de

surface mais de statut grammatical entièrement différent ? Un algorithme naïf ne peut trancher cette ambiguïté qu'au prix d'un traitement contextuel coûteux en ressources et potentiellement source d'erreurs, alors qu'un système à bi-univocité stricte l'éliminerait par construction.

Une difficulté de même nature affecte le digramme ng, dont un lecteur automatique ne peut, sans analyse contextuelle supplémentaire, distinguer avec certitude s'il encode le phonème unique /ŋ/ (consonne nasale palatale) ou bien la succession de deux consonnes distinctes n et g dans un mot composé ou à la frontière de deux morphèmes. Cette même ambiguïté existe, à un degré moindre mais réel, pour tout apprenant humain débutant qui doit mémoriser une règle contextuelle plutôt qu'une correspondance directe et stable entre son et symbole. À l'ère de l'intelligence artificielle générative et des grands modèles de langage entraînés sur corpus multilingues, cette ambiguïté structurelle complique en outre l'entraînement de modèles performants pour le créole haïtien, une langue déjà sous-représentée dans les corpus numériques mondiaux par rapport à son nombre de locuteurs.

2.3 Le cas de la voyelle fantôme u : anomalie phonologique de la séquence ui

Un cas particulier mérite une attention spécifique en raison de son caractère emblématique : celui de la séquence graphique ui, employée dans l'orthographe de 1979 pour transcrire des mots où le

son réellement prononcé correspond à la semi-consonne /w/ suivie de la voyelle /i/, soit /wi/ en notation phonétique internationale. Or, la lettre u, prise isolément, ne correspond à aucun phonème autonome et indépendant dans le système phonologique du créole haïtien : contrairement au français, où u note une voyelle antérieure fermée arrondie distincte, le créole ne connaît pas ce son comme unité phonémique séparée. La lettre u n'apparaît donc jamais seule dans l'orthographe créole ; elle n'existe qu'au sein de la séquence composite ui, ce qui en fait, au sens strict, une lettre fantôme — un vestige graphique sans existence phonologique autonome, hérité par analogie de conventions françaises et non justifié par la structure interne du créole lui-même.

Cette anomalie n'est pas seulement une curiosité théorique pour spécialiste : elle crée une difficulté pédagogique réelle pour l'apprenant, à qui l'on enseigne une lettre qui ne se prononce jamais isolément et dont la fonction ne peut être comprise qu'au travers d'une règle d'exception mémorisée séparément du reste du système. Elle crée également une anomalie computationnelle pour tout système de synthèse vocale ou de correction automatique, qui doit traiter u comme un cas particulier plutôt que comme une unité phonémique régulière au même titre que les autres voyelles de l'alphabet.

La solution la plus économe en principe et la plus cohérente avec l'architecture phonologique du créole consiste à substituer

systématiquement à la séquence *ui* la séquence *wi*, qui recourt exclusivement à des lettres déjà pourvues d'un statut phonologique autonome et stable dans le système de 1979 (la semi-voyelle *w* et la voyelle *i*), sans qu'il soit besoin d'introduire un graphème nouveau ni de modifier la prononciation réelle du mot concerné. C'est cette solution que retient et développe le chapitre suivant, consacré à la présentation détaillée de la réforme proposée.

2.4 L'inflation nominale de l'inventaire alphabétique

Un dernier constat, plus discret que les trois précédents mais tout aussi structurel, mérite d'être établi avant de refermer ce diagnostic. L'orthographe officielle de 1979, telle que reconduite sans modification par la résolution de l'Académie du Créole Haïtien de 2017, est traditionnellement enseignée et présentée comme comportant trente-deux lettres. Ce chiffre, largement répété dans les manuels scolaires et les supports pédagogiques, mérite un examen attentif : il additionne, sans les distinguer, des unités de nature très différente.

D'un côté figurent d'authentiques unités atomiques, irréductibles à toute décomposition ultérieure : les consonnes simples, les semi-voyelles *w* et *y*, les voyelles orales de base. De l'autre côté figurent les quatre séquences opaques déjà identifiées à la section 2.1 (*ch*, *ou*, *oun*, *ng*), comptées comme des lettres à part entière alors qu'elles sont, par construction, des combinaisons de deux ou trois symboles. Mais l'inventaire de 1979 va plus loin encore

dans cette confusion catégorielle : il compte également comme lettres distinctes les trois voyelles nasales an, en, on, ainsi que les trois voyelles accentuées à, è et ò — alors même que ces six séquences, on le montrera au chapitre III, s'analysent chacune comme l'application régulière d'une règle de composition à une voyelle orale déjà présente ailleurs dans le même alphabet.

Cette inflation nominale n'est pas qu'une curiosité taxonomique. Elle a une conséquence pédagogique directe : présenter à l'apprenant un alphabet de trente-deux lettres, quand seule une fraction de cet ensemble correspond à des unités véritablement irréductibles, revient à lui demander de mémoriser individuellement des éléments qui pourraient, au contraire, se déduire les uns des autres par l'application d'un petit nombre de règles générales. C'est précisément cette confusion entre lettre atomique et lettre combinée que le chapitre suivant se propose de dissiper, en proposant un inventaire recompté sur des bases rigoureuses.

SYNTHÈSE DU CHAPITRE — Quatre anomalies distinctes, mais convergentes, ont été identifiées : une entorse structurelle au principe de bi-univocité par la persistance de six séquences polygraphiques ; une ambiguïté algorithmique documentée dans les systèmes de traitement automatique du langage ; une lettre fantôme, u, dépourvue d'existence phonologique autonome ; et une inflation nominale de l'inventaire alphabétique, qui compte comme lettres indépendantes des combinaisons parfaitement régulières. Ces quatre constats appellent une réponse unique et cohérente : c'est l'objet du chapitre III.

Chapitre III — Proposition d'une réforme intégrale et protocole de normalisation numérique

Le diagnostic établi au chapitre précédent appelle une réponse systémique et non de simples correctifs isolés. Ce chapitre présente la proposition centrale du présent mémoire : l'Alphabet Atomique Créole, désigné par le sigle AAC, conçu comme l'achèvement logique et technique de la promesse fondatrice de la réforme de 1979 plutôt que comme sa remise en cause. Six axes structurent cette présentation : la définition du nouvel alphabet atomique et de ses graphèmes, la théorisation des principes de combinaison de lettres et de signes qui en assurent la cohérence pédagogique, le protocole concret d'implémentation technologique nécessaire à son adoption, la mise en regard critique avec les alternatives déjà écartées, la comparaison avec les propositions post-1979 existantes, et la délimitation précise du périmètre grammatical de la réforme.

DE L'ATOME À LA MOLÉCULE — L'AAC distingue strictement, à l'image de la chimie, une matrice d'éléments de base — vingt-quatre lettres atomiques, irréductibles — et les structures combinatoires infinies que la langue construit à partir d'elle. Aucun atome supplémentaire n'est requis pour écrire an, en, on, à, è, ò ou òn : ce sont des molécules, des assemblages réguliers et prévisibles d'atomes déjà présents dans la matrice, non des éléments à ajouter à celle-ci. Alléger l'alphabet ne restreint donc en rien le potentiel expressif de la langue : il en libère au contraire la capacité combinatoire, exactement comme un tableau

périodique restreint d'éléments chimiques stables suffit à engendrer l'infinie diversité des molécules du monde matériel.

3.1 Présentation du nouvel alphabet atomique

L'Alphabet Atomique Créole repose sur un principe sans exception et sans ambiguïté, que l'on peut nommer le dogme de la bi-univocité totale : à chaque phonème du créole haïtien correspond un graphème unique et non ambigu — étant entendu que certaines séquences déjà transparentes et déjà régulières de l'orthographe de 1979, telles que les nasales an, en et on, satisfont pleinement à ce principe sans qu'aucune modification graphique ne soit nécessaire. Ce principe est très précisément la promesse inaugurale de l'alphabet de 1979, que l'AAC se propose d'honorer dans sa plénitude, cinquante ans après sa formulation initiale.

3.1.1 *Qu'est-ce qu'un alphabet atomique ?*

Le présent mémoire nomme atomique un alphabet dont chaque lettre satisfait à trois conditions cumulatives : elle représente un son de base unique (un phonème), sous une forme de base unique (un graphème constant, sans variante contextuelle), et elle est elle-même irréductible — c'est-à-dire non décomposable en unités plus simples déjà présentes ailleurs dans le même alphabet. Un alphabet atomique n'interdit nullement les combinaisons de lettres : il exige seulement que ces combinaisons soient reconnues comme telles, plutôt que comptées à tort comme des lettres supplémentaires à mémoriser individuellement.

Or l'inventaire pédagogique de 1979, tel que reconduit sans modification par la résolution de l'Académie du Créole Haïtien de 2017, dénombre traditionnellement trente-deux lettres — un chiffre qui, ainsi que l'a établi la section 2.4, mélange deux catégories fondamentalement différentes. D'authentiques unités atomiques irréductibles y côtoient des combinaisons déjà décomposables mais comptées comme des lettres à part entière : les quatre séquences opaques *ch*, *ou*, *oun* et *ng*, déjà traitées par substitution aux sections qui suivent, mais aussi les trois voyelles nasales *an*, *en*, *on* et les trois voyelles accentuées *à*, *è*, *ò*, dont ni la graphie ni la prononciation ne sont modifiées par l'AAC, mais dont le statut théorique au sein de l'inventaire alphabétique doit être corrigé.

3.1.2 Les voyelles accentuées : combinaisons, non nouvelles lettres

Le créole haïtien ne connaît qu'un seul signe diacritique d'accentuation, l'accent grave — ou *aksan fòs* dans la terminologie créole — appliqué à trois des voyelles orales de base : *a*, *e* et *o*. Ainsi *à*, comme dans *anpàn*, *è*, comme dans *lanmè*, et *ò*, comme dans *lekòl* ou *mòn*, ne sont pas des lettres indépendantes du point de vue atomique : elles sont l'application d'un seul et même signe diacritique à une voyelle déjà présente ailleurs dans l'alphabet. Ce raisonnement est symétrique à celui développé pour les voyelles nasales à la section 3.2 : *an*, *en*, *on* n'y seront pas davantage traitées comme des lettres distinctes, mais comme l'application d'une même règle de composition (une consonne nasale *n* après une voyelle orale), aux

mêmes trois voyelles de base. Un seul et même geste théorique s'applique ainsi, de façon uniforme, à la fois aux voyelles nasalisées et aux voyelles accentuées : distinguer la lettre atomique irréductible de la combinaison régulière qu'elle permet de construire.

Il importe de souligner qu'aucune de ces trois voyelles accentuées ne voit son orthographe modifiée par l'AAC : à, è et ò continuent de s'écrire exactement comme dans l'orthographe de 1979. Ce qui change n'est donc pas la graphie des mots, mais le statut théorique de ces trois signes au sein de l'inventaire alphabétique — une distinction qui n'a aucune incidence sur le gain scriptural mesuré au chapitre IV, mais qui a une incidence directe sur la charge mnémotechnique nominale de l'alphabet, ainsi que le montre le tableau ci-dessous.

Voyelle atomique	Forme accentuée	Exemple	Statut
A	à	Anpàn	Combinaison (a + aksan fòs) — inchangée à l'écrit
E	è	Lanmè	Combinaison (e + aksan fòs) — inchangée à l'écrit
O	ò	lekòl, mòn	Combinaison (o + aksan fòs) — inchangée à l'écrit

Une précision technique s'impose ici, sans laquelle la cohabitation des règles de nasalisation (section 3.2) et d'accentuation exposées ci-dessus resterait incomplète. La règle de nasalisation par défaut énonce qu'une voyelle orale suivie de n en fin de syllabe se

nasalise automatiquement. L'aksan fòs joue, dans ce contexte précis, un rôle de marqueur d'exception : une voyelle accentuée suivie de n ne se nasalise pas, et le n conserve alors sa pleine valeur consonantique, prononcé séparément de la voyelle qui le précède. Le couple pàn (dans anpàn) et pan (dans panpan) illustre exactement cette distinction : pàn se prononce avec un à oral suivi d'un n consonantique bien distinct, exactement comme le an de l'ane dans le mot français savane, où le n, suivi d'une voyelle, reste consonantique et n'entraîne aucune nasalisation ; pan, à l'inverse, se prononce avec un an pleinement nasal, exactement comme le an final de maman en français, où le n s'efface derrière la nasalisation de la voyelle qui le précède. L'aksan fòs remplit ainsi une double fonction, phonétique et distinctive : il modifie le timbre de la voyelle de base, et il signale, lorsque cette voyelle est suivie de n, que la nasalisation par défaut est bloquée. Cette double fonction, loin de complexifier le système, en explicite une régularité qui restait jusqu'ici implicite dans l'orthographe de 1979.

3.1.3 Une conséquence bienvenue : la disparition de la lettre h

Le reclassement opéré par l'AAC entraîne une conséquence non recherchée mais bienvenue, qui mérite d'être signalée explicitement. Dans l'inventaire de 1979, la lettre h n'a pour seule fonction autonome que d'entrer dans la composition du digramme ch : elle n'apparaît, sauf de rares emprunts, dans aucun autre contexte fonctionnel du système. Dès lors que ce digramme est remplacé par le monogramme š, la lettre h cesse de remplir la moindre fonction

distinctive dans l'écriture du créole et peut, à bon droit, être retirée de l'inventaire atomique de l'AAC.

3.1.4 L'inventaire des vingt-quatre lettres atomiques

Au terme de ce reclassement, l'alphabet atomique de l'AAC comprend vingt-quatre lettres irréductibles : cinq voyelles, deux semi-voyelles et dix-sept consonnes.

Catégorie	Lettres atomiques	Nombre
Voyelles	a, e, i, o, ò	5
Semi-voyelles	w, y	2
Consonnes	b, š, d, f, g, j, k, l, m, n, ŋ, p, r, s, t, v, z	17
Total	—	24

Ce chiffre de vingt-quatre lettres, comparé aux trente-deux traditionnellement dénombrés dans le système de 1979, représente une réduction de vingt-cinq pour cent de l'inventaire alphabétique nominal. Cette réduction ne traduit à aucun moment une perte de capacité expressive : les sept séquences reclassées ou substituées ne disparaissent pas de l'écrit (an, en, on, à, è, ò continuent de s'écrire exactement comme avant, et ch, ou, oun, ng sont remplacés par leur monogramme respectif), mais cessent d'être comptées comme des unités à mémoriser séparément, puisqu'elles se déduisent toutes de règles de composition régulières et désormais explicites. De ces vingt-quatre lettres atomiques, la grammaire du créole engendre, par combinaison libre, un nombre en principe infini de digrammes,

trigrammes et mots, exactement comme les vingt-six lettres de l'alphabet latin engendrent l'intégralité du lexique français ou anglais sans qu'aucune de leurs combinaisons (ch, ou, an, th, ou ing en anglais), ne soit elle-même comptée comme une lettre supplémentaire de l'alphabet.

TROIS CHIFFRES, TROIS QUESTIONS DIFFÉRENTES —

Ce mémoire cite trois comptes distincts, qu'il importe de ne pas confondre : 32 répond à la question « combien de lettres l'enseignement traditionnel présente-t-il ? » (Compte nominal et pédagogique, incluant à tort des combinaisons) ; 24 répond à « combien de lettres irréductibles suffisent, par écrit, à engendrer tous les mots ? » (Compte de graphèmes, celui de l'AAC) ; 30 répond à « combien de sons distincts la langue parlée possède-t-elle réellement ? » (Compte phonémique, détaillé en annexe). Les quatre voyelles nasales sont de vrais sons distincts, donc comptées dans les 30, mais ne reçoivent pas de lettre dédiée à l'écrit, donc absentes des 24. À l'inverse, à n'est pas un son distinct de a — seuls è et ò le sont de e et o —, ce qui explique que le compte phonémique (30) ne soit ni le double ni un simple sous-ensemble du compte de graphèmes (24). Le détail complet de cette distinction figure dans l'annexe phonologique.

3.1.5 Comparaison des inventaires alphabétiques nominaux

Le tableau suivant situe ce reclassement par rapport aux deux autres systèmes déjà présentés à la section 3.5 : l'orthographe officielle de 1979 et la proposition du linguiste Frantz Gourdet (2022). Il apparaît que ni l'une ni l'autre ne procède à ce recomptage : le système de 1979 dénombre traditionnellement trente-deux lettres, tandis que la proposition Gourdet, bien que recourant elle

aussi à des monogrammes pour les voyelles nasales (ä, ë, ö, ü), continue de les compter comme des lettres à part entière au même titre que les lettres irréductibles — une démarche de substitution symbole pour symbole qui n'opère aucune réduction du compte nominal de l'alphabet. Les deux approches partagent ainsi une même logique implicite, celle d'un symbole dédié par phonème, quand l'AAC en défend une autre, celle d'un symbole dédié par phonème irréductible seulement, les phonèmes dérivés se déduisant de règles de composition.

Catégorie	Officiel 1979 / AKA 2017	Gourdet (2022)	AAC
Voyelles orales de base	a, e, i, o (+ digramme ou)	a, e, i, o, u (u redéfini)	a, e, i, o, ǫ
Voyelles nasales	an, en, on, oun — comptées comme lettres	ä, ë, ö, ü — monogrammes dédiés, toujours comptés comme lettres	Non comptées — combinaisons (voyelle + n)
Voyelles accentuées	à, è, ò — comptées comme lettres	à, è, ò — statut inchangé	Non comptées — combinaisons (voyelle + aksan fòs)
/ʃ /	ch (digramme)	c (monogramme)	š (monogramme)
/ɲ /	ng (digramme)	ng (non traité)	ŋ (monogramme)
/ɥ i/	Ui	Yw	wi
Semi-voyelles	w, y	w, y	w, y
Lettre h	h — fonction limitée à ch	h — statut inchangé	Supprimée (fonction absorbée par š)
Nombre total de lettres nominales	32	Non réduit — substitution symbole pour symbole	24

3.1.6 Principes de conception

L'AAC ne crée pas une nouvelle langue, ne modifie en rien la prononciation créole, et ne remet nullement en cause les acquis fondamentaux du décret de 1979. Il se limite, avec une discipline délibérée et volontairement minimale, à remplacer les quatre séquences véritablement opaques de l'orthographe actuelle — ch, ou, oun et ng — par des graphèmes simples et immédiatement disponibles, et à reclasser six séquences déjà transparentes (an, en, on, à, è, ò) comme combinaisons plutôt que comme lettres, selon trois principes de conception inviolables.

- **Parcimonie de graphèmes** : seules les séquences phonologiquement opaques — c'est-à-dire les combinaisons de lettres dont la prononciation ne peut être déduite de la simple lecture des lettres qui la composent, telles que ch, ou, oun et ng — sont concernées par la réforme. Les séquences déjà transparentes et régulières, comme an, en et on, ne sont volontairement pas modifiées : un système ne doit être corrigé que là où il est réellement défaillant.
- **Rétrocompatibilité visuelle** : chaque nouveau graphème porte en lui la mémoire morphologique de la ou des lettres qu'il remplace. Un lecteur déjà formé au système de 1979 peut déchiffrer intuitivement les nouveaux graphèmes, sans apprentissage préalable complet ni rupture de continuité générationnelle.
- **Faisabilité technique immédiate** : la totalité des graphèmes proposés — š, ǒ, ŋ — sont d'ores et déjà encodés dans des

blocs Unicode universellement disponibles et présents nativement dans toutes les fontes standard des systèmes d'exploitation contemporains. Aucun développement typographique, aucune fonte dédiée et aucune zone d'usage privé ne sont nécessaires : c'est un choix de conception délibéré, retenu précisément pour son coût technique quasi nul.

Note officielle sur le statut des semi-voyelles W et Y

PÉRIMÈTRE DE LA RÉFORME — Les lettres W et Y conservent intégralement leur graphie, leur statut phonologique et leur rôle grammatical tels qu'établis par le décret officiel du 28 septembre 1979. Ces deux semi-voyelles/consonnes ne font l'objet d'aucune modification dans le cadre de la réforme AAC, qui cible exclusivement et précisément l'élimination des digrammes et trigrammes résiduels de l'orthographe créole officielle. Le reste du système de 1979 est intégralement préservé. Cette clarification est apportée afin de lever toute ambiguïté sur le périmètre, volontairement restreint et non révolutionnaire, de la réforme proposée.

Tableau comparatif des trois systèmes graphiques

Le tableau ci-dessous synthétise, pour chacun des six phonèmes concernés, la notation du système Pressoir antérieur à 1979, la notation officielle actuellement en vigueur, et la proposition AAC, accompagnée de sa justification linguistique et technique.

API	Pressoir (avant 1979)	Officiel 1979	AAC (proposition)	Justification linguistique et technique
/ʃ /	ch	Ch	š (U+0161)	S caron (API/pinyin/langues slaves et baltes). Déjà présent dans toute table Unicode et toute fonte standard. Aucune police à développer, aucun symbole à créer : disponibilité immédiate sur tous les systèmes.
/u/, /ü/	ou, oun	ou, oun	ö	O à brève concave note le son /u/. Lorsque ce son est nasalisé (mot autrefois écrit oun), il suffit d'appliquer à ö la même règle de composition déjà en vigueur pour an, en et on, sans qu'aucun symbole distinct ne soit introduit : ö suivi de n note naturellement /ü/. Corps o intact, racine visuelle familière, deux gestes manuscrits contre trois pour « ou ».
/ã/	an	An	an (inchangé)	Séquence phonotactique transparente et non modifiée : a + n. Un apprenant qui sait déjà écrire a et n écrit an sans effort ni règle supplémentaire, exactement comme en espagnol ou en anglais. Aucun symbole nouveau requis.
/ẽ/	en	En	en (inchangé)	Séquence phonotactique transparente et non modifiée : e + n. Même logique de composition naturelle que an et on, sans exception ni diacritique.
/õ/	on	On	on (inchangé)	Séquence phonotactique transparente et non modifiée : o + n. Complète le trio nasal an/en/on, laissé intact par choix délibéré de parcimonie de graphèmes.
/ɲ /	gn / ng	Ng	ɲ (U+014B)	Eng (API). Déjà présent dans les fontes Unicode standard (Noto, Arial Unicode MS, Segoe UI). Supprime l'ambiguïté n+g pour les moteurs de segmentation.

API	Pressoir (avant 1979)	Officiel 1979	AAC (proposition)	Justification linguistique et technique
W, Y	w, y	w, y	w, y (inchangés)	Statut conservé intégralement. Les semi-voyelles/consonnes w et y ne sont pas concernées par la réforme, qui cible exclusivement les digrammes et trigrammes opaques résiduels.
/ɥi/	ui	Ui	wi (séquence)	Glissement naturel de deux phonèmes déjà existants (w + i). Aucun graphème nouveau requis : décision délibérée de parcimonie de graphèmes.

* La notation « ſ » (s caron, U+0161) est un caractère latin standard, présent dans le bloc Unicode Latin Extended-A depuis l'origine même du standard Unicode. Il est déjà utilisé pour des fonctions phonétiques comparables dans plusieurs langues d'usage courant — le tchèque, le slovaque, le letton, le lituanien, le slovène ou le croate — ainsi que dans les systèmes de translittération scientifique. Sa disponibilité est donc immédiate sur tout clavier, tout système d'exploitation et toute fonte installée par défaut, sans qu'aucun développement typographique ni aucune zone d'usage privé ne soient nécessaires — condition de faisabilité déterminante dans l'arbitrage documenté à la section 3.4.

3.2 Théorisation de la combinaison phonotactique et diacritique

Le principe qui gouverne l'ensemble des arbitrages de conception de l'AAC peut être formulé comme un principe de combinaison, distinguant rigoureusement deux catégories de séquences graphiques au sein de l'orthographe de 1979 : les séquences transparentes, dont la prononciation se déduit directement et sans exception de la lecture successive des lettres et

signes qui la composent, et les séquences opaques, dont la prononciation ne peut être devinée par la simple lecture séquentielle des lettres et qui doivent, de ce fait, être mémorisées comme des unités arbitraires distinctes.

Les nasales an, en et on appartiennent sans conteste à la première catégorie. Le créole haïtien applique en effet, de façon parfaitement régulière et sans exception documentée, la règle phonotactique suivante : une voyelle orale suivie de la consonne n en fin de syllabe se nasalise. Cette règle n'est pas propre au créole : elle est strictement analogue au fonctionnement de la nasalisation en espagnol ou à la valeur de n en position implosive dans de nombreuses langues romanes et anglo-saxonnes. Un apprenant qui sait déjà écrire et prononcer isolément la lettre a et la lettre n déduit sans effort supplémentaire la prononciation de la séquence an, exactement comme il déduirait celle de en ou de on à partir des mêmes briques déjà connues. Il n'existe donc, pour ces trois séquences, strictement aucune opacité à corriger : elles sont déjà, dans leur forme actuelle héritée de 1979, un exemple accompli de combinaison phonotactique.

Les voyelles accentuées à, è et ò relèvent d'une combinaison de nature légèrement différente, mais tout aussi transparente : non plus phonotactique (l'assemblage de deux lettres consécutives), mais diacritique (l'application d'un signe à une lettre de base). Le créole haïtien n'emploie qu'un seul accent, l'aksan fòs, et l'applique de façon

uniforme aux trois voyelles a, e, o pour en marquer le timbre ouvert. Un apprenant qui a compris cette règle unique (l'aksan fòs, apposé à une voyelle, en modifie le timbre de façon prévisible), n'a besoin de mémoriser ni à, ni è, ni ò comme des lettres séparées : il lui suffit de reconnaître, sur la lettre de base déjà connue, l'application d'un seul et même signe diacritique déjà présent dans l'alphabet de 1979. Comme pour les nasales, aucune opacité véritable ne justifie ici de modification graphique : à, è et ò continuent de s'écrire exactement comme avant. L'aksan fòs remplit en outre, on l'a détaillé à la section 3.1.2, une seconde fonction lorsqu'il précède la consonne n : il bloque la nasalisation par défaut et restitue au n sa pleine valeur consonantique, comme dans le couple pàn/pan — une régularité supplémentaire, et non une exception arbitraire, puisqu'elle découle directement et systématiquement de la présence ou de l'absence du même signe diacritique.

Les séquences ch, ou, oun et ng, à l'inverse, appartiennent à la catégorie de l'opacité véritable, qu'elle soit liée à la combinaison des lettres ou à l'usage des signes. Aucune règle générale et régulière du créole ne permet à un apprenant de déduire, à partir de la seule lecture successive des lettres c et h, que leur combinaison notera le son /ʃ / plutôt que la succession des deux consonnes qu'elles notent isolément par ailleurs. Il en va de même pour o suivi de u, dont la combinaison note un son, /u/, qui n'est déductible d'aucune règle de composition régulière à partir des valeurs isolées de o et de u — ce dernier n'ayant d'ailleurs, comme l'a montré le chapitre II, aucune

existence phonologique autonome en créole. Il en va de même, enfin, pour n suivi de g, dont la combinaison note un son unique, /ɲ/, sans lien déductible avec la lecture séquentielle de n et de g. Ces quatre séquences doivent donc être mémorisées par l'apprenant comme des exceptions arbitraires à la règle générale de lecture séquentielle des lettres — ce qui est, précisément, la définition même d'une irrégularité orthographique.

L'AAC applique à cette distinction une conséquence logique directe et volontairement minimale : seules les séquences véritablement opaques (ch, ou, oun, ng), sont remplacées par un graphème simple, immédiatement disponible dans le standard Unicode, tandis que les séquences déjà transparentes — an, en, on, à, è, ò — sont conservées à l'identique, sans la moindre modification graphique, mais reclassées comme combinaisons plutôt que comme lettres distinctes au sein de l'inventaire atomique présenté à la section 3.1.4. Ajouter un tilde à une séquence déjà parfaitement régulière, ou inventer un nouveau signe pour une voyelle déjà correctement décodée par tout apprenant, n'aurait apporté, à l'analyse, aucun gain pédagogique réel : cela aurait au contraire introduit un coût de frappe et d'apprentissage supplémentaire là où le système actuel ne présente, précisément, aucune défaillance à corriger. C'est ce principe de parcimonie et d'intervention strictement ciblée qui distingue l'AAC d'une réforme diacritique généralisée, et qui en fait une proposition délibérément minimale : corriger uniquement ce qui est réellement irrégulier, et rien de plus.

Démonstration lexicale : de la théorie aux mots réels

Le tableau suivant applique l'ensemble des règles énoncées ci-dessus à des mots réels du créole haïtien, y compris le couple mòn/moun, dont la distinction illustre à elle seule la cohérence du système : deux mots fréquents, phonologiquement proches, désormais distingués par deux règles diacritiques principales plutôt que par une opposition orthographique ò/ou qui devait auparavant être mémorisée cas par cas.

Mot (1979)	AAC	Analyse combinatoire
Manman	manman	a + n : combinaison nasale par défaut, deux occurrences, inchangée.
Moun	mõn	m + õ (remplace ou) + n : combinaison nasale par défaut appliquée à õ.
Mòn	mòn	m + ò (o + aksan fòs) + n : l'accent bloque la nasalisation, le n reste consonantique. Contraste directement avec mõi ci-dessus — deux mots, deux règles, deux résultats distincts.
Chèche	šèšè	š (remplace ch, deux occurrences) + è (e + aksan fòs, inchangé) + š + e.
Anpàn	anpàn	a + n (nasale) + p + à (a + aksan fòs, bloque la nasalisation du n qui suit) + n consonantique.
Lang	laŋ	l + a + ŋ (remplace ng) : monogramme unique pour la consonne nasale palatale.

3.3 Guide d'implémentation technologique

La légitimité linguistique d'une réforme graphématique, aussi rigoureusement établie soit-elle, ne suffit pas à en garantir l'adoption effective. L'histoire des réformes orthographiques mondiales

enseigne qu'un système, même supérieur sur le plan théorique, ne s'impose que s'il est immédiatement utilisable dans les conditions matérielles réelles d'écriture contemporaine : claviers physiques et virtuels, systèmes d'exploitation, polices de caractères, moteurs de rendu web et modèles d'intelligence artificielle. Le choix de fonder l'AAC exclusivement sur des graphèmes déjà standardisés (š, ǒ, ŋ), simplifie considérablement ce protocole, comme le détaille cette section.

3.3.1 Standardisation des claviers physiques et virtuels

L'adoption des trois nouveaux graphèmes de l'AAC suppose leur disponibilité immédiate et intuitive sur les dispositifs de saisie utilisés quotidiennement par les locuteurs créolophones : claviers virtuels des téléphones mobiles Android et iOS, claviers physiques et virtuels des systèmes Windows et macOS. Le protocole d'implémentation prévoit le développement de dispositions clavier conformes au Common Locale Data Repository (CLDR), le référentiel international de l'Unicode Consortium pour les données linguistiques et régionales, permettant l'intégration native de l'AAC dans les systèmes d'exploitation grand public sans nécessiter d'application tierce. Les graphèmes š, ǒ et ŋ, déjà présents dans les blocs Unicode existants, sont accessibles par des combinaisons de touches mortes standard (touche diacritique suivie de la lettre de base), à l'instar des conventions déjà en usage pour le tchèque, le turc ou le vietnamien — aucune touche ni disposition entièrement inédite n'est nécessaire.

3.3.2 Encodage Unicode et normalisation ISO

Sur le plan de l'encodage informatique, la totalité des trois graphèmes de l'AAC — š (U+0161), ö (U+014F) et ŋ (U+014B) — sont d'ores et déjà couverts par les blocs Unicode Latin Extended-A et Latin Extended-B, universellement disponibles sur l'ensemble des systèmes d'exploitation contemporains depuis plus de deux décennies. Cette situation garantit une compatibilité immédiate et sans réserve, sans nécessiter la moindre mise à jour logicielle côté utilisateur final, la moindre zone d'usage privé transitoire, ni la moindre procédure de soumission au Consortium Unicode — à la différence de la ligature géométrique initialement envisagée et écartée pour cette raison précise à la section 3.4.1.

En parallèle de cette absence de besoin d'encodage nouveau, le protocole prévoit néanmoins le dépôt d'un dossier de documentation de l'AAC auprès de l'organisation internationale de normalisation, au titre de l'ISO 15924, référentiel international des codes de représentation des noms de systèmes d'écriture, à des fins de reconnaissance et de traçabilité internationale du système orthographique en tant que tel — une démarche purement documentaire, sans dépendance vis-à-vis d'un calendrier de normalisation incertain.

3.3.3 Entraînement des modèles d'intelligence artificielle

L'intégration de l'AAC dans les corpus d'entraînement des grands modèles de langage constitue un enjeu stratégique spécifique

à l'ère actuelle. Un système à bi-univocité renforcée élimine, comme l'a montré le chapitre II, une part des ambiguïtés de segmentation lexicale qui compliquent aujourd'hui l'entraînement de modèles performants pour le créole haïtien, tout en demeurant, grâce au caractère déjà standardisé de ses trois graphèmes, immédiatement compatible avec l'ensemble des bibliothèques de traitement de texte existantes, sans adaptation technique particulière. Le protocole d'implémentation recommande la constitution, dès la phase 2, d'un corpus de référence bilingue (orthographe 1979 / orthographe AAC) destiné à alimenter les outils de conversion automatique et à faciliter l'adaptation progressive des modèles de traitement automatique du langage existants, qu'il s'agisse de correcteurs orthographiques, de systèmes de synthèse et de reconnaissance vocale, ou d'assistants conversationnels pour le créole haïtien — un domaine où la langue demeure aujourd'hui nettement sous-représentée au regard de son nombre de locuteurs.

3.3.4 Feuille de route de déploiement en quatre phases

La mise en œuvre de l'AAC est conçue comme un processus progressif et réversible à chaque étape, structuré en quatre phases dont le calendrier indicatif est résumé dans le tableau suivant. L'absence de tout développement typographique requiert notamment un calendrier sensiblement plus court que celui d'une réforme impliquant la création d'une fonte dédiée.

Phase	Contenu et livrables
Phase 1 — Validation académique (mois 0–4)	Présentation officielle du présent mémoire à l'Académie du Créole Haïtien en session plénière ; constitution d'un groupe de travail interdisciplinaire (linguistes, typographes, ingénieurs informaticiens, pédagogues, représentants des communautés scolaires) ; consultation élargie des communautés éducatives en Haïti et dans la diaspora (États-Unis, Canada, France, Québec) ; adoption d'une résolution de principe autorisant le lancement de la phase 2.
Phase 2 — Outillage numérique (mois 4–10)	Développement et publication des dispositions clavier officielles CLDR pour Windows, macOS, Android et iOS, intégrant š, ǒ et ǣ par touches mortes standard ; aucune fonte nouvelle à créer, les trois graphèmes étant déjà couverts par les fontes système existantes (Noto, Arial, Segoe UI, San Francisco) ; développement d'outils de conversion automatique bidirectionnelle (1979 → AAC) pour traitement de texte et systèmes de gestion de contenu ; publication de ces outils en licence libre sur GitHub.
Phase 3 — Déploiement pilote (mois 6–12, en parallèle de la phase 2)	Déploiement expérimental dans la signalétique numérique publique d'une commune test (affichage LED des transports en commun, marchés, administrations) ; intégration dans les menus et interfaces d'une application ministérielle ou universitaire partenaire ; collecte et analyse des métriques de validation (lisibilité, taux d'erreur de frappe, satisfaction utilisateur, charge serveur) ; publication d'un rapport d'évaluation intermédiaire à l'issue des six mois.
Phase 4 — Officialisation (mois 18–24)	Dépôt de la norme AAC auprès de l'ISO 15924 à titre de documentation du système d'écriture ; publication du décret de révision orthographique officielle par le ministère de l'Éducation Nationale ; lancement de l'édition nationale des premiers manuels scolaires en orthographe AAC. Aucune démarche de normalisation Unicode n'est requise à ce stade, les trois graphèmes de l'AAC étant déjà pleinement standardisés.

PRINCIPE DIRECTEUR DE LA TRANSITION — À aucune étape de ce protocole la validité de l'orthographe de 1979 n'est remise en cause : l'AAC est conçu comme un système additionnel et convertible, coexistant avec la norme officielle actuelle pendant toute la durée de la phase pilote, et non comme une abrogation immédiate imposée par décret sans période

d'adaptation. Cette approche progressive est développée plus en détail au chapitre IV, section 4.3, consacrée à la viabilité et au coût de la transition.

3.4 Alternatives envisagées et raisons de leur écartement

La rigueur scientifique impose de documenter non seulement la solution retenue, mais également les alternatives sérieusement envisagées au cours de l'élaboration de l'AAC et les raisons précises de leur écartement. Cette démarche critique renforce la crédibilité de la proposition finale en montrant qu'elle résulte d'un processus d'arbitrage raisonné plutôt que d'un choix arbitraire ou définitif dès la première esquisse.

3.4.1 La ligature géométrique *ch* pour le son /ʃ /

Une version de travail antérieure à la rédaction définitive de ce mémoire envisageait de noter le son /ʃ / au moyen d'une ligature géométrique originale, fusionnant graphiquement les lettres c et h en un caractère unique et inédit. Cette solution présentait un argument réel : celui d'une signature visuelle entièrement propre à la langue créole, sans équivalent préexistant dans aucune autre tradition orthographique, ce qui en aurait fait un symbole fort de souveraineté graphique.

Elle a cependant été écartée au profit du monogramme š (s caron, U+0161) pour trois raisons convergentes, décisives dans l'arbitrage final. Premièrement, une ligature inédite ne possède, par définition, aucune existence dans le standard Unicode : son adoption

aurait imposé le développement d'une fonte typographique dédiée, l'hébergement transitoire du glyphe dans une zone d'usage privé fragile et non portable d'un système à l'autre, puis une longue procédure de soumission au Consortium Unicode dont l'issue et le délai (souvent plusieurs années), ne sont jamais garantis à l'avance. Deuxièmement, ce coût de développement et cette incertitude technique sont sans commune mesure avec le bénéfice symbolique recherché, alors qu'une solution immédiatement disponible existe déjà dans le répertoire Unicode standard. Troisièmement, le monogramme š, loin d'être une simple facilité, est un choix linguistiquement documenté : il est déjà utilisé pour une fonction phonétique strictement comparable dans plusieurs langues d'usage courant (tchèque, slovaque, letton, lituanien, slovène, croate) ainsi que dans les systèmes de translittération scientifique, ce qui atteste de sa robustesse et de sa lisibilité éprouvée à grande échelle.

Le monogramme š a donc été préféré à la ligature géométrique pour des raisons de fond, de faisabilité et de parcimonie : il satisfait pleinement au principe de faisabilité technique immédiate énoncé à la section 3.1, sans qu'aucun développement de police, aucune zone d'usage privé ni aucune démarche de normalisation internationale ne soient nécessaires — ce qui simplifie très substantiellement la feuille de route de déploiement présentée à la section 3.3.4.

3.4.2 *Le tilde de nasalité pour an, en et on*

Une seconde alternative, également documentée dans les travaux préparatoires à ce mémoire, proposait de noter les trois voyelles nasales du créole au moyen d'un diacritique tilde superposé à la voyelle orale de base (ã, ã , õ), sur le modèle de la convention de nasalité employée en portugais ou en vietnamien. Cette solution présentait l'avantage d'unifier visuellement les trois sons nasaux sous une règle diacritique unique et de réduire, marginalement, le nombre de caractères nécessaires à leur transcription.

Elle a cependant été écartée au moment de l'arbitrage final, pour une raison de fond antérieure à toute considération de gain scriptural : les séquences an, en et on, comme l'établit la théorisation de la section 3.2, sont déjà des séquences phonotactiquement transparentes, parfaitement régulières et sans exception dans le système actuel — un apprenant qui sait déjà écrire a et n déduit sans effort la lecture de an, exactement comme il le ferait en espagnol. Introduire un diacritique là où le système est déjà intuitivement décodable n'aurait apporté aucun gain pédagogique réel, tout en ajoutant un coût de frappe supplémentaire sur les claviers mobiles, où la saisie de caractères accentués requiert systématiquement une touche morte ou une pression prolongée. Le gain scriptural associé au tilde, au demeurant modeste puisque limité à un caractère par occurrence, ne compensait pas ce coût ergonomique ajouté à une séquence qui, à la différence de ch, ou ou ng, ne présentait par ailleurs aucune opacité à corriger.

C'est pour ces raisons que l'AAC retient, à la section 3.1, le principe inverse : an, en et on demeurent rigoureusement inchangés par rapport à l'orthographe de 1979, sans le moindre diacritique, en stricte application du principe de parcimonie de graphèmes qui gouverne l'ensemble de la réforme — ne corriger que ce qui est réellement irrégulier, et rien de plus.

3.4.3 Pourquoi pas un monogramme d'inspiration africaine ?

Le choix du monogramme š, emprunté à la tradition orthographique tchèque et à la notation scientifique internationale, appelle une question légitime compte tenu de l'origine du créole haïtien : puisque cette langue est née, comme l'a établi le chapitre I, du contact entre plusieurs langues africaines (notamment le fon, l'ewé, le wolof et le kikongo), et le français colonial, un monogramme d'inspiration africaine n'aurait-il pas constitué un choix plus cohérent, sur le plan symbolique comme linguistique, qu'un emprunt à une langue slave sans lien historique avec Haïti ? Cette question mérite un examen systématique plutôt qu'une réponse de principe.

L'examen des orthographes africaines les plus consultées pour ce type de comparaison fait apparaître trois catégories de résultats, aucune ne plaidant en faveur d'un monogramme d'inspiration africaine pour le cas précis du /j / créole.

Première catégorie : des digrammes, pas des monogrammes

Le swahili et le lingala, deux langues bantoues de grande diffusion internationale, notent toutes deux le son /ʃ / par le digramme sh — c'est-à-dire par la même stratégie graphique, à une lettre près, que le digramme ch de l'orthographe créole de 1979. Retenir ce modèle n'aurait résolu strictement aucune des anomalies documentées au chapitre II : la séquence resterait plurigraphique, ambiguë pour la segmentation lexicale automatique, et coûteuse en caractères. Le cas du lingala est plus instructif encore : ce digramme y est d'un usage si marginal qu'il est aujourd'hui largement supplanté par la lettre z dans l'usage courant, signe d'une convention orthographique elle-même instable et non consensuelle.

Deuxième catégorie : un phonème absent des langues du substrat

Le cas du wolof, du fon et de l'éwé — ces deux dernières étant précisément comptées, au chapitre I, parmi les langues africaines à l'origine du créole haïtien — est plus surprenant encore. Le wolof ne possède pas de /ʃ / comme phonème autonome ; son inventaire consonantique le plus proche est /tʃ /, noté c, un son de nature différente. L'éwé, quant à lui, ne connaît le son [ʃ] que comme variante positionnelle du phonème /s/ devant la voyelle /i/ dans certains parlers méridionaux — une réalisation purement contextuelle et prévisible, qui ne reçoit à ce titre aucune lettre dédiée dans l'orthographe éwé. Il n'existe donc, à proprement parler, aucun modèle africain de référence pour l'écriture de ce son : les langues

mêmes qui ont donné au créole haïtien une part de son patrimoine phonologique n'ont jamais eu à résoudre ce problème, parce que le /ʃ / n'y fonctionne pas comme un phonème indépendant.

Troisième catégorie : un vrai monogramme, mais une leçon involontaire

Le yoruba constitue le seul contre-exemple sérieux. Sa norme orthographique panafricaine (dite pan-nigériane) note le /ʃ / par le monogramme ₣ — un s affecté d'un point souscrit, pourvu d'un codepoint Unicode dédié (U+1E62 en majuscule, U+1E63 en minuscule) et donc, en apparence, immédiatement disponible. C'est le seul système africain examiné qui satisfasse au critère strict d'unicité graphique posé au chapitre III.

Un examen de la littérature scientifique consacrée au traitement automatique du yoruba révèle cependant un défaut structurel documenté et récurrent : les caractères accentués par point souscrit, dont ₣ , sont massivement omis dans l'écriture numérique courante, au point que la restauration automatique des diacritiques constitue aujourd'hui un sous-domaine à part entière de la recherche en traitement automatique du yoruba, avec ses propres corpus de référence et ses propres modèles dédiés. Ce phénomène n'est pas anecdotique : il signifie que la solution graphique retenue par le yoruba pour /ʃ / reproduit, à grande échelle et de façon documentée, précisément le type d'ambiguïté algorithmique que le chapitre II du présent mémoire reproche à l'orthographe créole

actuelle. Adopter ce modèle n'aurait donc pas résolu le problème diagnostiqué : il l'aurait importé sous une forme différente.

POURQUOI LE CARON RÉSISTE MIEUX — Le mécanisme documenté pour le yoruba n'est pas propre à cette langue : un signe diacritique placé sous la lettre, à proximité de la ligne de base, est structurellement plus vulnérable à l'omission (à la frappe comme à la lecture rapide), qu'un signe placé au-dessus, dans l'espace visuel déjà occupé par les ascendantes. Ce constat rejoint directement l'argument de départ de ce choix : en contexte diglossique, où l'œil et les doigts du scripteur créolophone sont façonnés par des décennies de pratique du français, un point sous le s a toutes les chances de subir le même sort que le point souscrit yoruba. Un caron au-dessus du s, en revanche, prolonge une convention diacritique déjà acquise par tout lecteur créolophone : è et ò, dans l'orthographe de 1979, portent déjà leur signe distinctif au-dessus de la lettre. Le š ne crée donc aucune zone diacritique nouvelle ; il étend une convention existante.

Trois arguments supplémentaires confortent ce choix. Premièrement, la cohérence systémique : plaçant son diacritique au-dessus de la lettre comme è et ò, le š s'insère dans une convention visuelle déjà familière, alors qu'un point souscrit inaugurerait une zone diacritique sans aucun précédent dans le système de 1979. Deuxièmement, la lisibilité en conditions d'affichage dégradées : sur les afficheurs à faible résolution déjà évoqués à la section 4.2.4, un point sous la lettre est le premier élément à disparaître ou à se confondre avec un signe de ponctuation, quand un caron détaché en hauteur résiste mieux à la perte de définition. Troisièmement, la

neutralité symbolique du signe : au-delà de son usage tchèque, le caron sur le s est la notation standard de plusieurs traditions scientifiques internationales, tels que : la notation américaniste, l'alphabet phonétique ouralien, la translittération ISO 9 du cyrillique etc. ce qui en fait moins un emprunt culturel circonstanciel qu'un symbole scientifique de facto pour ce phonème précis. Cette neutralité s'inscrit d'ailleurs dans la continuité d'un principe déjà appliqué par l'orthographe de 1979 elle-même : è et ò empruntent leur diacritique à la tradition typographique française sans que cela n'ait jamais été perçu comme une atteinte à la souveraineté graphique du créole. Le š ne fait, à cet égard, que suivre un précédent déjà établi par la norme qu'il complète.

3.5 Tableau comparatif des alphabets atomiques du créole haïtien postérieurs à 1979

Depuis l'officialisation de l'alphabet de 1979, plusieurs linguistes ont continué à publier des propositions de perfectionnement de la graphie créole, sans qu'aucun consensus national ne se soit à ce jour dégagé. Deux jalons post-1979 méritent d'être situés par rapport à l'AAC avant toute présentation de cette dernière comme aboutissement : la résolution de l'Académie du Créole Haïtien de 2017, et la proposition savante la plus aboutie en matière d'alphabet à monogrammes, formulée par le linguiste Frantz Gourdet dans le cadre de sa théorie dite du linéarisme.

La première résolution de l'Académie du Créole Haïtien, publiée le 1er juin 2017, a reconduit intégralement l'alphabet de 1979 tel quel, sans y apporter la moindre modification de graphème : ses neuf dispositions portent sur des points connexes — forme longue et courte des mots, usage de l'apostrophe et du tiret, orthographe des noms propres, emploi des graphèmes *r* et *w*, accentuation — mais laissent inchangés les sept séquences de combinaison doubles et triples de graphèmes identifiées au chapitre II. À ce jour, aucune réforme atomique de l'alphabet n'a donc été officiellement adoptée par l'institution habilitée à le faire.

Sur le plan strictement académique, la proposition la plus rigoureusement construite en ce sens reste celle du linguiste Frantz Gourdet, publiée en 2022 dans la revue *Rechèch Etid Kreyòl*. Fondée sur une théorie linguistique originale, dite du linéarisme, cette proposition introduit un jeu de graphèmes monogrammatiques alternatifs — repris pour l'essentiel du principe déjà esquissé par McConnell et Laubach dans les années 1940 — destinés à remplacer les séquences *ch*, *ou*, *oun*, *an*, *en* et *on* par des monogrammes accentués uniques : *c*, *u*, *ü*, *ä*, *ë* et *ö* respectivement. Cette proposition présente l'intérêt scientifique majeur d'être la seule, à notre connaissance, à avoir formalisé un système monogrammatique complet pour l'ensemble des sept séquences polygraphiques du système de 1979, y compris les trois séquences nasales.

Son (API)	Officiel 1979 / AKA 2017	Proposition Gourdet (2022)	AAC (présente proposition)
/ʃ /	Ch	C	š
/u/	Ou	U	ō
/ũ/	oun	Ü	ö suivi de n (automatique)
/ã/	An	Ä	an (inchangé)
/ẽ/	En	Ë	en (inchangé)
/õ/	On	Ö	on (inchangé)
/ɲ /	Ng	ng (non traité)	ŋ
/ɥi/ ~ /jw/	Ui	Yw	wi

NOTE DE BAS DE TABLEAU — Justification du maintien de

an, en et on — L'AAC se distingue délibérément de la proposition Gourdet (2022) sur un point précis : là où celle-ci étend la logique monogrammatique aux trois séquences nasales an, en et on en leur adjoignant un tréma (ä, ë, ö), l'AAC fait le choix inverse et les laisse rigoureusement inchangées. Ce choix n'est pas un renoncement mais une application stricte du principe de parcimonie de graphèmes établi à la section 3.2 : an, en et on sont des séquences phonotactiquement transparentes — un apprenant qui sait déjà écrire une voyelle et la consonne n en déduit la lecture sans effort ni règle supplémentaire, exactement comme en espagnol — et ne présentent, à la différence de ch, ou, oun et ng, aucune opacité réelle à corriger. Leur doter d'un diacritique supplémentaire, comme le propose la théorie linéariste, offrirait un gain scriptural marginal au prix d'un coût de frappe et d'apprentissage ajouté à une séquence qui n'en avait pas besoin. L'AAC préfère donc supprimer ce surplus diacritique au profit de la langue elle-même : au profit de sa régularité déjà acquise, de la vitesse de frappe de

ses locuteurs sur clavier mobile, et de la continuité visuelle immédiate avec l'orthographe de 1979 que pratiquent déjà onze millions de créolophones. C'est très précisément la même logique qui a conduit à écarter le tilde de nasalité généralisé à la section 3.4.2 du présent mémoire.

Ce positionnement contrasté permet de mieux cerner la spécificité de l'AAC au sein du paysage des propositions post-1979 : une intervention strictement ciblée sur les quatre séquences réellement opaques (ch, ou, oun, ng), fondée exclusivement sur des graphèmes déjà standardisés dans le Unicode courant, là où la proposition Gourdet, plus ambitieuse dans sa cohérence théorique, touche six séquences sur sept et laisse le son /ɲ / (ng) non traité. Les deux démarches partagent cependant un même constat de fond, documenté au chapitre II : la solidité du principe phonologique de l'alphabet de 1979 comme fondement légitime de l'orthographe créole, que ni l'une ni l'autre ne remet en cause. Sur un point précis, cependant, l'AAC se distingue des deux systèmes examinés dans cette section : ni l'orthographe de 1979 ni la proposition Gourdet ne remettent en cause le compte nominal de l'alphabet lui-même, qui demeure fixé à trente-deux lettres dans le premier cas et n'est pas réduit dans le second, malgré le recours à des monogrammes dédiés pour les nasales. Seul l'AAC opère, à la section 3.1, le reclassement théorique qui ramène cet inventaire à vingt-quatre lettres véritablement irréductibles.

3.6 L'AAC et la grammaire créole : une réforme strictement de graphèmes

Il importe d'établir sans ambiguïté, avant de clore ce chapitre, le périmètre exact de la réforme proposée : l'AAC est une intervention orthographique, non une intervention grammaticale. Aucune règle de morphologie, de syntaxe ou de sémantique du créole haïtien n'est modifiée, ajoutée ou supprimée par l'AAC. La structure sujet-verbe-objet, les marqueurs aspecto-temporels du verbe (te pour l'accompli, ap pour le progressif, pral et va pour le futur, sot pour le passé récent), le marqueur du pluriel yo, les pronoms personnels, les constructions de négation (pa), les déterminants et toute autre règle grammaticale du créole demeurent, après adoption de l'AAC, rigoureusement identiques à ce qu'ils sont dans l'orthographe de 1979.

Une précision s'impose cependant, par souci d'exhaustivité et de rigueur : les substitutions graphiques de l'AAC s'appliquent mécaniquement à toute occurrence des séquences ch, ou, oun et ng dans un texte, y compris lorsque ces séquences apparaissent à l'intérieur de mots grammaticaux plutôt que de mots lexicaux pleins. C'est le cas, notamment, du pronom personnel de deuxième personne ou (tu, toi), qui devient ۆ ; du pronom de première personne du pluriel nou (nous), qui devient nõ ; et de la préposition pou (pour), qui devient pۆ. Ces trois mots grammaticaux, parmi les plus fréquents de la langue, voient donc leur orthographe évoluer au

même titre que n'importe quel mot lexical contenant la même séquence.

Ce constat n'affaiblit en rien la thèse centrale de cette section : la fonction grammaticale de ces mots (leur rôle de pronom ou de préposition, leur position dans la phrase, leur comportement syntaxique), demeure exactement identique. Seule leur représentation graphique change, exactement selon la même logique mécanique que pour tout autre mot du lexique. La phrase *Ou pral wè si ou vle* (Tu verras si tu veux) devient, en AAC, *Ö pral wè si ò vle* : le marqueur de futur *pral*, la conjonction *si* et la structure de la phrase restent inchangés ; seul le pronom *ou*, à ses deux occurrences, adopte sa nouvelle graphie *ö*.

PÉRIMÈTRE CONFIRMÉ — L'AAC ne touche à aucune règle de grammaire créole. Les quelques mots grammaticaux à haute fréquence contenant les séquences *ch*, *ou*, *oun* ou *ng* (*ou*, *nou*, *pou* notamment) changent de graphie exactement comme n'importe quel autre mot du lexique, sans que leur fonction, leur distribution syntaxique ou leur comportement morphologique ne soient affectés. La réforme reste, dans sa totalité, une réforme de l'écrit, non de la langue elle-même.

Chapitre IV — Évaluation des impacts : gains économiques, sociaux et accélération de l'apprentissage

Après avoir exposé, au chapitre III, l'architecture linguistique et technique de l'Alphabet Atomique Créole, ce quatrième chapitre en évalue les impacts prévisibles selon trois axes complémentaires : un axe quantitatif, mesurant le gain scriptural sur un corpus littéraire de référence et ses projections à l'échelle éditoriale nationale ; un axe psycholinguistique et didactique, évaluant la réduction de charge cognitive attendue chez l'apprenant ; et un axe stratégique, consacré à la viabilité et au coût d'une transition maîtrisée.

4.1 Analyse quantitative du gain scriptural

4.1.1 Exemples d'application directe

Avant d'engager une analyse quantitative rigoureuse sur corpus, il est utile d'illustrer concrètement la transformation opérée par l'AAC sur des phrases réelles du créole haïtien courant.

Exemple 1 — traitement des digrammes ch et ou :

Graphie 1979 : « Chita sou chèz la pou lannwit la pa fini. »
Version AAC : « Šita sō šèz la pō lannwit la pa fini. » Le remplacement du digramme ch par le monogramme š et du digramme ou par le monogramme ō élimine, dans chaque cas, la lettre surnuméraire, sans que la prononciation du mot ne soit en rien

modifiée. La séquence lannwit, déjà conforme à la règle wi présentée à la section 2.3, demeure inchangée.

Exemple 2 — traitement du digramme ng :

Graphie 1979 : « Solèy la ap klere sou gwo bangan an nan vil la. »
 » Version AAC : « Solèy la ap klere sǒ gwo bangan an nan vil la. »
 Le remplacement du groupe complexe ng par le symbole unique ŋ permet à tout algorithme de lecture automatique de savoir immédiatement qu'il s'agit d'un seul phonème et non d'une succession fortuite de la consonne n suivie de la consonne g, tandis que la séquence nasale an, en fin de phrase, demeure rigoureusement inchangée.

Exemple 3 — synthèse sur un texte complexe :

Graphie 1979 : « Chak moun gen dwa pou yo chèche travay san pwoblèm nan peyi a. »
 » Version AAC : « Šak mǒn gen dwa pǒ yo šěše travay san pwoblèm nan peyi a. »
 Cette phrase illustre la convergence des trois règles de l'AAC au sein d'un même énoncé : le monogramme š pour les deux occurrences de ch, le monogramme ǒ pour les deux occurrences de ou (dont une en position nasale, moun devenant mǒn par simple application à ǒ de la même règle de composition n déjà en vigueur pour an, en et on), et la conservation strictement inchangée des séquences nasales déjà transparentes gen, san, pwoblèm et nan, ainsi que des lettres w et y.

4.1.2 Étude de corpus : l'extrait de René Depestre

Afin de valider l'AAC dans des conditions textuelles réelles et non plus seulement sur des exemples isolés, un corpus de référence a été retenu : un extrait de la traduction créole haïtienne d'une strophe de René Depestre, né en 1926 à Jacmel, l'une des voix majeures de la littérature caribéenne et de la négritude, dont l'œuvre (de *Étincelles* (1945) à *Hadriana dans tous mes rêves*, Prix Renaudot 1988), est marquée par l'exil, la résistance politique et la revendication de l'identité haïtienne. La richesse phonologique de son écriture créolisée en fait un corpus de référence pertinent pour valider l'AAC en conditions textuelles authentiques, au-delà des exemples pédagogiques construits.

Le texte original, en français, évoque la clarté de la langue maternelle rayonnant sur les écrans du monde — un thème dont la résonance avec l'objet même du présent mémoire n'est pas fortuite. La transcription créole officielle de 1979 et sa transposition intégrale en AAC sont présentées dans le tableau ci-dessous, avec le décompte précis des caractères pour chaque version.

Version	Texte créole (extrait du corpus)	Car. total	Car. sans esp.	Gain
Créole 1979	Chante pou chase lapli nan kò mwen, chante pou san mwen rete cho nan tanpèt la, pou klète lang manman nou klere sou ekran toupatou sou latè.	140	114	—
AAC	Šante pō šase lapli nan kò mwen, šante pō san mwen rete šo nan tanpèt la, pō klète lan manman nō klere sō ekran tōpatō sō latè.	127	101	−9,3 %

Le détail des substitutions observées sur ce corpus est le suivant : le digramme *ch*, remplacé par le monogramme *š*, apparaît à quatre occurrences et représente à lui seul quatre caractères économisés ; le digramme *ou*, remplacé par *ö*, apparaît à huit occurrences pour un total de huit caractères économisés ; le digramme *ng*, remplacé par *ŋ*, apparaît à une occurrence pour un caractère économisé. Les séquences nasales *an* et *en*, conformément au principe de parcimonie établi au chapitre III, ne sont volontairement pas modifiées et ne contribuent donc à aucune économie de caractères, ni à aucune perte : elles demeurent identiques à l'orthographe de 1979. Au total, sur ce corpus de cent quarante caractères, l'AAC réalise un gain net de neuf virgule trois pour cent en comptage total, et de onze virgule quatre pour cent hors espaces, soit treize caractères économisés sans qu'aucune information phonétique ne soit perdue et sans qu'aucun graphème nouveau ne soit requis au-delà des trois définis au chapitre III.

4.1.3 Projection à grande échelle : impact éditorial et écologique

Le gain de neuf virgule trois pour cent mesuré sur le corpus Depestre — un texte littéraire de densité digrammatique modérée, dans lequel les séquences nasales déjà transparentes *an* et *en* restent, par construction, sans contribution à l'économie de caractères — constitue une mesure conservatrice de l'économie réalisable. Les textes à vocation éducative, tels que les manuels scolaires, les cahiers d'exercices et les consignes pédagogiques, présentent une densité de

digrammes opaques (ch, ou, oun, ng) systématiquement supérieure à celle du corpus littéraire de référence, ce qui porte le gain réel observable entre neuf et treize pour cent selon le type de document considéré.

Ces projections, calculées sur la base d'un tirage hypothétique mais réaliste de cinq cent mille exemplaires du manuel officiel de l'éducation primaire haïtienne et d'un taux moyen de onze pour cent, permettent d'apprécier concrètement l'ampleur de l'impact éditorial et environnemental d'une adoption généralisée de l'AAC dans le système scolaire national.

Scénario	Volume original (1979)	Volume AAC	Économie réalisée
Manuel scolaire de 200 pages	200 pages	≈ 178 pages	22 pages économisées (-11 %)
Tirage national de 500 000 exemplaires	100 millions de pages	89 millions de pages	11 millions de pages
Papier consommé (estimation)	≈ 550 tonnes / an	≈ 490 tonnes / an	≈ 60 tonnes / an
Équivalent en arbres préservés	Référence	—	≈ 1 000 arbres / an
Réduction des émissions de CO ₂	Base 100	—	≈ 9 % de réduction

Les soixante tonnes de papier économisées annuellement selon cette projection correspondent à l'abattage d'environ mille arbres évités chaque année — un argument environnemental précis et directement communicable auprès des institutions internationales de financement du développement éducatif, telles que la Banque

mondiale, l'Agence des États-Unis pour le développement international ou l'Organisation internationale de la Francophonie. L'économie directe sur les seuls coûts d'impression demeure substantielle pour le seul segment des manuels scolaires du primaire, sans compter les économies induites dans l'édition privée, la presse écrite et l'administration publique — un gain d'autant plus notable qu'il s'obtient, comme le montre la section 4.3, pour un coût de développement technique quasi nul.

4.2 Impact psycholinguistique et didactique

4.2.1 *Le principe d'automaticité de la lecture*

La recherche contemporaine en neurosciences de la lecture démontre de façon convergente que l'acquisition fluide de la lecture repose sur la formation de correspondances directes, stables et sans ambiguïté entre un son phonologique et une forme visuelle unique — ou, à défaut, sur une règle de composition parfaitement régulière et sans exception, telle que celle qui gouverne déjà *an*, *en* et *on* en créole. Ce constat, largement établi dans la littérature scientifique consacrée à l'apprentissage de la lecture, s'applique directement au cas des séquences réellement opaques du créole : lorsqu'un son est représenté par une combinaison de lettres dont la prononciation ne se déduit d'aucune règle générale (comme c'est le cas de *ch*, *ou*, *oun* et *ng* dans le système de 1979), le lecteur débutant doit mémoriser cette combinaison comme une exception arbitraire, au détriment de la ressource cognitive qu'il pourrait consacrer directement à la

compréhension sémantique du message lu. L'AAC élimine cette surcharge exactement là où elle existe réellement, en rendant ces quatre séquences visuellement uniques et prévisibles, sans toucher aux séquences nasales déjà transparentes.

4.2.2 Le tracé continu et la mémoire motrice scolaire

En psychologie de l'écriture manuscrite, chaque interruption du tracé (chaque lever du stylo entre deux lettres ou à l'intérieur même d'une lettre), mobilise un coût cognitif mesurable de l'ordre de quatre-vingts à cent vingt millisecondes et introduit un risque accru de déformation du caractère suivant, particulièrement chez le scripteur débutant. Le digramme *ch* de l'orthographe officielle de 1979 nécessite, selon le style cursif de l'élève haïtien, entre cinq et sept gestes manuscrits distincts pour transcrire deux sons pourtant simples et fréquents. Le monogramme *ś*, en revanche, se trace en deux gestes séquentiels déjà connus de tout élève créolophone — le corps du *s*, puis le petit accent en chevron renversé au-dessus — puisque le geste du *s* est identique à celui déjà appris pour cette lettre, et le caron se superpose selon un geste de diacritique déjà pratiqué pour d'autres lettres accentuées de l'alphabet créole telles que *è* ou *ò*. Ce programme moteur, ne reposant sur aucun geste inédit, ne requiert donc aucune démonstration spécifique ni séance de pratique guidée supplémentaire.

4.2.3 *Trois substitutions ciblées : mémorisation minimale*

L'intégralité du système AAC est enseignable au moyen de trois substitutions ponctuelles, chacune remplaçant une séquence réellement opaque de l'orthographe de 1979 par un graphème unique et déjà familier dans sa logique diacritique, sans qu'aucune règle nouvelle ne soit introduite pour les séquences déjà transparentes.

- Substitution 1 — š remplace ch : le monogramme se lit comme un s auquel s'ajoute le trait phonétique de chuintement déjà connu du digramme qu'il remplace. Aucune nouvelle règle de nasalité ou de composition n'est impliquée.
- Substitution 2 — ō remplace ou : la brève concave apposée sur le o signifie le son fermé /u/. Le graphème ō se lit intuitivement comme un o modifié, et se combine simplement avec n selon la règle de composition déjà en vigueur pour an, en et on lorsque ce même son est nasalisé (mot autrefois écrit oun) : aucun symbole distinct n'est introduit pour ce cas, qui découle automatiquement de la même logique.
- Substitution 3 — ŋ remplace ng : le symbole eng, déjà connu de la notation phonétique internationale, note directement le son nasal palatal sans risque de confusion avec la succession des consonnes n et g.

Ces trois substitutions couvrent la totalité des séquences véritablement opaques identifiées au chapitre II. Les séquences an,

en et on, à l'inverse, ne font l'objet d'aucune substitution et ne requièrent, de ce fait, strictement aucun apprentissage supplémentaire par rapport au système actuellement enseigné dans les écoles primaires haïtiennes : c'est précisément cette économie de moyens, ciblant exclusivement les quatre séquences opaques et laissant intactes les trois séquences déjà régulières, qui constitue le principal gain didactique de l'AAC par rapport à une réforme diacritique généralisée qui aurait modifié l'ensemble des sept séquences sans discrimination.

Ce gain didactique se double d'un gain de nature plus strictement mnémotechnique, établi à la section 3.1 : en reclassant an, en, on, à, è et ò comme des combinaisons régulières plutôt que comme des lettres distinctes de l'alphabet, l'AAC ramène l'inventaire alphabétique nominalelement enseigné à l'apprenant de trente-deux à vingt-quatre lettres irréductibles, soit vingt-cinq pour cent d'unités en moins à mémoriser individuellement en tout début d'apprentissage — avant même que ne s'exercent les trois substitutions elles-mêmes.

4.2.4 Arguments industriels et numériques complémentaires

Les systèmes d'affichage dynamique, dits digital signage, utilisés dans les transports en commun, les aéroports, les terminaux portuaires, les marchés publics et les administrations haïtiennes, reposent sur des afficheurs à diodes électroluminescentes matriciels à capacité contrainte, typiquement de seize à quarante caractères par

ligne. Dans ce contexte technique précis, chaque caractère économisé produit un effet direct et mesurable : augmentation de la quantité d'information affichable par ligne sans recours au défilement temporisé, amélioration de la distance maximale de lisibilité, et réduction de la consommation énergétique par cycle d'affichage. Sur un afficheur standard de trente-deux positions organisées en seize colonnes et deux lignes, le gain de l'AAC représente concrètement deux à quatre caractères supplémentaires disponibles par ligne — un gain plus modeste que dans les versions antérieures de la réforme, mais obtenu sans aucun développement typographique, ce qui en renforce la viabilité immédiate.

4.3 Viabilité et coût de transition

Aucune réforme graphématique, quelle que soit la solidité de sa justification scientifique, ne peut être évaluée sans une analyse rigoureuse de son coût de transition et des risques associés à sa mise en œuvre. Trois catégories de coûts doivent être distinguées : le coût de développement technique, le coût de formation des enseignants et des usagers, et le coût de réédition du corpus documentaire et littéraire existant.

Le coût de développement technique, détaillé au chapitre III, est le plus significativement réduit par rapport aux versions antérieures de la réforme : puisque les trois graphèmes de l'AAC (š, ō, ŋ), sont d'ores et déjà couverts par le standard Unicode et présents nativement dans toutes les fontes système courantes, aucune fonte

dédiée ne doit être développée. Le coût se limite à la publication de dispositions clavier et d'outils de conversion automatique, un investissement mineur et rapidement amortissable.

Le coût de formation, quant à lui, est directement atténué par le principe de parcimonie de graphèmes qui gouverne l'ensemble de la conception de l'AAC : un enseignant déjà formé à l'orthographe de 1979 peut s'approprier le nouveau système en quelques heures de formation continue, dans la mesure où aucune règle grammaticale ou lexicale n'est modifiée, où les séquences nasales *an*, *en* et *on* restent rigoureusement inchangées, et où seules quatre séquences opaques déjà connues (*ch*, *ou*, *oun*, *ng*) évoluent vers un graphème unique. Les trois substitutions présentées à la section 4.2.3 sont précisément conçues pour minimiser ce coût de formation initiale.

Le coût de réédition du corpus existant, enfin, est le plus significatif à long terme, mais il est structurellement pris en charge par la stratégie de déploiement en quatre phases exposée au chapitre III : les outils de conversion automatique développés dès la phase 2 permettent une translittération assistée, et non manuelle, de l'ensemble du corpus numérique existant (littérature, presse, documentation administrative), réduisant ainsi considérablement le travail de réédition à une tâche de vérification et de relecture plutôt que de retranscription intégrale. La coexistence prolongée des deux systèmes pendant la phase pilote, garantie par le principe directeur de la transition énoncé au chapitre III, assure en outre qu'aucun

document existant ne devient subitement illisible ou obsolète du fait de la réforme.

4.4 Discussion critique : objections anticipées et éléments de réponse

Toute proposition de réforme orthographique, aussi documentée soit-elle, doit anticiper les objections légitimes qui ne manqueront pas d'être soulevées lors de son examen par l'Académie du Créole Haïtien et par la communauté scientifique. Cette section en discute cinq, choisies pour leur caractère structurant.

4.4.1 « *Le système de 1979 fonctionne déjà : pourquoi le modifier ?* »

Cette objection, la plus fondamentale, est en un sens la plus juste : le système de 1979 fonctionne, et fonctionne bien, comme l'attestent les progrès de l'alphabétisation en créole depuis son adoption. Le présent mémoire ne conteste à aucun moment cette réussite. Il en propose au contraire, comme l'indique son titre même, l'achèvement plutôt que le remplacement : les quatre séquences opaques ciblées représentent une fraction résiduelle et clairement circonscrite d'un système par ailleurs presque intégralement régulier — les séquences nasales *an*, *en* et *on*, on l'a montré, n'ayant précisément pas besoin d'être modifiées puisqu'elles sont déjà transparentes. L'argument n'est donc pas que le système de 1979 aurait échoué, mais qu'un système fonctionnel peut, cinquante ans après sa conception, bénéficier d'une optimisation strictement ciblée sur ses seules irrégularités réelles.

4.4.2 « Le gain scriptural mesuré (9 à 13 %) est plus modeste que dans les versions antérieures de la réforme : celle-ci reste-t-elle justifiée ? »

Cette observation est exacte : en renonçant au tilde de nasalité pour préserver l'intégrité des séquences *an*, *en* et *on* déjà transparentes, l'AAC renonce mécaniquement à une partie du gain scriptural qu'une réforme diacritique généralisée aurait pu revendiquer. Ce choix est cependant assumé et délibéré, pour deux raisons. D'une part, le gain pédagogique associé au tilde était largement illusoire, comme l'a établi la section 3.4.2 : une séquence déjà régulière ne devient pas plus facile à apprendre parce qu'on la 'orne' d'un diacritique. D'autre part, et surtout, le coût de mise en œuvre de l'AAC s'en trouve lui-même considérablement réduit : trois graphèmes déjà standardisés, aucune fonte à développer, aucune procédure de normalisation internationale à engager. Le rapport entre le bénéfice obtenu et le coût de transition engagé s'en trouve donc, toutes choses égales par ailleurs, nettement amélioré par rapport à une réforme plus ambitieuse en apparence mais plus coûteuse et plus incertaine à déployer.

4.4.3 « Pourquoi ne pas être allé plus loin en simplifiant également *an*, *en* et *on* ? »

Cette objection inverse mérite elle aussi d'être discutée. Une réforme plus radicale aurait pu, en toute cohérence théorique, appliquer un traitement diacritique uniforme à l'ensemble des sept séquences identifiées au chapitre II, sans distinguer les séquences opaques des séquences transparentes. Le choix inverse, retenu par

l'AAC, repose sur un principe de méthode explicité à la section 3.2 : une réforme orthographique ne doit intervenir que là où le système présente une défaillance réelle et démontrable, faute de quoi elle s'expose à un coût d'adoption disproportionné par rapport à son bénéfice. Les séquences an, en et on, déjà décodables sans ambiguïté par tout apprenant maîtrisant les lettres a, e, o et n prises isolément, ne présentent aucune défaillance de cette nature. Les modifier aurait ajouté un coût de frappe et d'apprentissage sans bénéfice pédagogique correspondant — l'exact inverse de la logique de parcimonie qui structure l'ensemble de la présente proposition.

4.4.4 « L'usage de diacritiques tels que le caron et la brève complique la frappe rapide sur clavier mobile »

Cette préoccupation ergonomique mérite d'être prise au sérieux, dans la mesure où la frappe sur clavier mobile constitue aujourd'hui, pour la majorité des locuteurs créolophones, le principal mode d'écriture quotidienne de la langue. Elle doit cependant être relativisée : l'AAC, en renonçant au tilde pour les nasales, ne mobilise plus que deux graphèmes accentués sur l'ensemble du système (š et ǫ), contre cinq dans les versions antérieures de la réforme envisagées dans les travaux préparatoires. L'expérience internationale de langues à diacritiques modérément présents en contexte mobile (le tchèque, le turc), démontre que ce coût résiduel, réel au moment de l'apprentissage initial, s'efface rapidement avec l'habitude. Le protocole d'implémentation présenté au chapitre III prévoit en outre le développement de dispositions clavier optimisées, incluant des

touches mortes dédiées, afin de minimiser ce coût ergonomique dès la phase de développement technique.

4.4.5 « Le décompte de vingt-quatre lettres n'est-il qu'un artifice rhétorique, puisque à, è, ò, an, en et on continuent de s'écrire exactement comme avant ? »

L'objection est légitime et mérite une réponse précise plutôt qu'une pirouette. Il est exact qu'aucun mot du créole ne change d'orthographe du fait de ce reclassement : lekòl s'écrit lekòl, manman s'écrit manman, avant comme après l'AAC. Ce que le reclassement modifie n'est donc pas l'écriture des mots, mais le compte de ce qui doit être enseigné comme une unité alphabétique irréductible — une distinction qui n'a rien d'un artifice, puisqu'elle est déjà universellement pratiquée pour d'autres langues sans que quiconque songe à la contester. Le français compte vingt-six lettres dans son alphabet nominal, bien que les mots français regorgent des combinaisons ch, ou, an, on, in, ein, ain ou eau : personne n'en conclut que le français possède en réalité trente-trois ou quarante lettres. Ces combinaisons sont universellement reconnues comme des faits d'orthographe, non comme des lettres supplémentaires de l'alphabet. Le présent mémoire applique très exactement le même principe de distinction au créole, avec cette différence que l'inventaire pédagogique de 1979 n'avait, jusqu'ici, jamais opéré cette clarification pour les nasales et les voyelles accentuées, les laissant comptées, dans les faits, comme des lettres à part entière.

Le bénéfice de ce recomptage n'est donc pas scriptural — il ne modifie aucun texte, et n'affecte en rien les gains en caractères mesurés à la section 4.1 — mais strictement pédagogique et cognitif : il réduit de vingt-cinq pour cent le nombre d'unités que l'enseignant doit présenter comme des lettres autonomes lors de l'apprentissage initial de l'alphabet, au profit d'un petit nombre de règles de composition généralisables. Un gain plus modeste qu'une réduction du texte lui-même, certes, mais un gain réel, mesurable en nombre d'unités mnémotechniques, et cohérent avec la pratique linguistique internationale la plus courante.

BILAN DU CHAPITRE — Les données rassemblées dans ce chapitre convergent vers une conclusion cohérente : les gains attendus de l'AAC — de l'ordre de 9 à 13 % en économie de caractères, une réduction de vingt-cinq pour cent de l'inventaire alphabétique nominal (32 → 24 lettres), une réduction ciblée de la charge mnémotechnique limitée aux quatre seules séquences réellement opaques de l'orthographe actuelle, et des économies significatives sur le plan écologique et budgétaire à l'échelle nationale.

— sont réels et documentés, tout en demeurant volontairement modestes par construction. Ce choix de parcimonie a pour contrepartie un coût de transition quasi nul, puisqu'aucun développement typographique ni aucune procédure de normalisation internationale ne sont requis, les trois graphèmes retenus étant déjà pleinement standardisés.

Chapitre V — Intelligence artificielle et traitement automatique du créole : la tokenisation à l'ère des grands modèles de langage

Les chapitres précédents ont mentionné, à plusieurs reprises, l'impact des digrammes créoles sur les systèmes de traitement automatique du langage naturel, sans jamais en détailler le mécanisme technique. Ce chapitre comble cette lacune : il explique précisément comment les grands modèles de langage contemporains, qu'il s'agisse de GPT, de Claude ou de tout autre système fondé sur l'architecture transformer, traitent le texte écrit, pourquoi l'orthographe créole actuelle y introduit une ambiguïté structurelle spécifique, et selon quel protocole concret l'AAC pourrait obtenir, à terme, une tokenisation véritablement optimale.

5.1 Comprendre la tokenisation : comment un modèle de langage « lit » un texte

Contrairement à une intuition répandue, un grand modèle de langage ne lit jamais directement des lettres ou des mots. Avant tout traitement, un module appelé tokeniseur découpe le texte d'entrée en unités appelées tokens — des séquences de caractères qui peuvent correspondre à un mot entier, à une partie de mot, ou même à un seul caractère selon les cas. Chaque token est ensuite converti en un identifiant numérique, seule forme que le modèle manipule réellement. La qualité de ce découpage initial conditionne

directement la qualité de tout ce qui suit : compréhension, traduction, génération.

La méthode de tokenisation la plus répandue dans les modèles contemporains, dite Byte Pair Encoding (BPE) ou l'une de ses variantes proches (WordPiece, SentencePiece), fonctionne par apprentissage statistique sur un corpus d'entraînement massif. L'algorithme part de l'unité la plus élémentaire (le caractère, ou même l'octet), puis fusionne itérativement les paires de symboles les plus fréquemment observées côte à côte dans le corpus, jusqu'à obtenir un vocabulaire d'une taille fixée à l'avance, typiquement de l'ordre de cinquante mille à deux cent mille unités. Un mot très fréquent dans le corpus d'entraînement devient ainsi un token unique ; un mot rare, ou une langue peu représentée, se voit découpé en davantage de fragments plus courts.

Ce vocabulaire de tokens, une fois établi lors de l'entraînement du modèle, demeure figé : il ne peut être modifié qu'au prix d'un réentraînement complet ou d'une procédure spécialisée d'extension de vocabulaire. C'est cette rigidité qui rend la question du choix orthographique directement pertinente pour l'intelligence artificielle : la façon dont une langue est écrite au moment de la constitution des corpus d'entraînement détermine, pour la durée de vie du modèle, l'efficacité avec laquelle cette langue sera traitée.

5.2 Pourquoi les digrammes créoles interfèrent avec les modèles entraînés majoritairement sur le français

Le créole haïtien partage l'alphabet latin avec le français, et l'orthographe de 1979 partage de surcroît, lettre pour lettre, plusieurs de ses séquences les plus fréquentes (ch, ou, an, en, on), avec cette même langue. Cette coïncidence graphique n'est pas neutre du point de vue d'un tokeniseur entraîné sur un corpus où le français est représenté en très large majorité par rapport au créole, situation qui reflète directement la disparité de volume documentaire déjà évoquée au chapitre III.

Dans un tel corpus, la séquence ch est fusionnée en un ou plusieurs tokens dont la distribution contextuelle d'apprentissage est presque entièrement déterminée par ses usages français (chat, chose, chercher, chaque). Lorsque cette même séquence apparaît dans un texte créole, le modèle ne dispose d'aucun signal orthographique lui permettant de savoir immédiatement qu'il traite une langue différente : le token est identique, octet pour octet, dans les deux langues. Le modèle doit alors s'en remettre au contexte élargi pour lever l'ambiguïté — une charge cognitive computationnelle supplémentaire, plus coûteuse et plus sujette à l'erreur sur des textes courts, des messages informels ou des contenus mêlant les deux langues, situation extrêmement fréquente dans la pratique réelle des locuteurs créolophones.

L'AAC répond directement à ce problème par construction : les monogrammes š, ō et ŋ n'existent dans aucun mot français. Un token contenant l'un de ces caractères ne peut, par définition, provenir que d'un texte créole. Cette propriété fait de ces trois graphèmes des marqueurs de langue non ambigus au niveau même du token — une forme de signalisation linguistique directement inscrite dans l'écriture, que ni ch ni ou ne peuvent offrir tant qu'ils demeurent des séquences partagées avec le français.

5.3 Un problème documenté à l'échelle des langues à faibles ressources

Le phénomène décrit à la section précédente n'est pas une spéculation propre au présent mémoire : il rejoint un champ de recherche établi en traitement automatique du langage, celui de l'équité dite « tokenistique » entre langues. Une étude de référence publiée lors de la conférence NeurIPS 2023 a mesuré, pour un même contenu informationnel, des écarts de fertilité tokenistique, le nombre moyen de tokens nécessaires pour représenter un mot ou une phrase, pouvant atteindre un facteur de quinze entre les langues les mieux desservies par les tokeniseurs actuels et les langues les moins bien desservies, ces dernières étant systématiquement les langues à faibles ressources documentaires.

Il importe cependant de distinguer soigneusement, par souci de rigueur, deux problèmes de nature différente, que l'AAC ne résout pas au même titre. Le premier est un problème de volume : le créole

haïtien demeure, dans l'absolu, sous-représenté dans les corpus d'entraînement des grands modèles actuels, indépendamment de toute question orthographique — ce problème ne se résout que par la constitution et la diffusion de corpus créoles plus vastes, quelle que soit la graphie retenue. Le second est un problème de distinctivité : à volume égal, une orthographe qui partage ses séquences les plus fréquentes avec une langue dominante s'expose à une conflation représentationnelle que ne connaît pas une orthographe dotée de marqueurs graphiques propres. C'est ce second problème, et lui seul, que l'AAC adresse directement ; le premier demeure entièrement tributaire d'un effort de constitution de corpus, traité à la section 5.6.

5.4 Tableau comparatif face au défi de la tokenisation

Le tableau suivant compare les trois systèmes déjà examinés au chapitre III sur des critères propres au traitement automatique du langage. Il est présenté en termes structurels et qualitatifs plutôt qu'en nombres de tokens mesurés sur un tokeniseur particulier : aucun tokeniseur de production actuel n'a été entraîné sur un corpus AAC, ce qui rendrait toute mesure chiffrée à ce stade non représentative de la performance attendue à terme, une fois l'adoption engagée.

Critère	Officiel 1979	Gourdet (2022)	AAC
Chevauchement graphique avec le français (ch, ou)	Total	Partiel (ou résolu, ch partagé)	Minimal (š, ō absents du français)

Critère	Officiel 1979	Gourdet (2022)	AAC
Séquences nasales partagées avec le français (an, en, on)	Total	Résolu (ä, ë, ö)	Total, mais phonotactiquement non ambigu (cf. 3.2)
/ɲ / (ng) résolu	Non	Non (non traité)	Oui (ŋ)
Empreinte Unicode des nouveaux graphèmes	—	Latin Extended-A/B (ă, ě, ő, ü)	Latin Extended-A/B (š, ǒ, ŋ)
Risque de repli en octets bruts à court terme (avant réentraînement)	Nul	Modéré	Modéré
Nécessite un corpus dédié pour bénéfice optimal en TALN	—	Oui	Oui
Ambiguïté de segmentation ou/conjonction résolue	Non	Oui	Oui

5.5 Ce qui change à court terme, ce qui change à long terme

Une honnêteté méthodologique s'impose ici, dans la continuité de la démarche suivie tout au long de ce mémoire : à très court terme, c'est-à-dire avant toute intégration d'un corpus AAC dans l'entraînement des tokeniseurs existants, un texte écrit en AAC ne bénéficiera pas nécessairement d'une tokenisation plus compacte que le même texte en orthographe de 1979. Les caractères š, ǒ et ŋ, absents ou rares dans les corpus d'entraînement actuels, risquent au contraire d'être découpés en unités plus élémentaires, voire, dans le pire des cas, en séquences d'octets bruts, par des tokeniseurs qui n'ont simplement jamais rencontré ces graphèmes en contexte créole suffisamment fréquent.

C'est précisément la situation que rencontre, à des degrés divers, toute innovation orthographique confrontée à des systèmes d'intelligence artificielle déjà entraînés : le bénéfice n'est jamais immédiat, il est différé jusqu'à ce qu'un volume suffisant de texte dans la nouvelle graphie ait été intégré à une génération ultérieure de modèles. Ce délai ne constitue pas un argument contre l'AAC ; il constitue un argument pour engager, dès à présent, la constitution du corpus qui rendra ce bénéfice effectif — objet de la section suivante.

5.6 Protocole de mise en œuvre : comment obtenir une tokenisation optimale pour l'AAC

Obtenir, à terme, une tokenisation réellement optimale pour l'AAC auprès des principaux fournisseurs de modèles de langage suppose une stratégie délibérée, non un simple effet d'attente. Cinq leviers concrets, cumulatifs et non exclusifs, sont recommandés.

- Constitution d'un corpus AAC de volume significatif : traduire ou convertir, à l'aide des outils de conversion automatique déjà développés (chapitre III, section 3.3.3), un corpus existant de littérature, de presse et de documentation créole vers l'AAC, puis le publier en accès libre. La taille de ce corpus est le facteur le plus déterminant : un tokeniseur ne peut apprendre des fusions efficaces pour des motifs qu'il n'a jamais rencontrés en quantité suffisante.

- Diffusion sur les plateformes de données ouvertes utilisées pour l'entraînement des modèles : dépôt du corpus sur des agrégateurs multilingues largement utilisés dans la constitution des jeux d'entraînement contemporains (dépôts de données ouvertes de type Common Crawl dérivé, OSCAR, ou des plateformes communautaires de partage de jeux de données), de façon à maximiser la probabilité d'inclusion dans un futur cycle d'entraînement, sans dépendre d'une négociation directe avec un fournisseur unique.
- Prise de contact directe avec les équipes responsables des données multilingues des principaux laboratoires d'intelligence artificielle : plusieurs organisations sollicitent activement des contributions communautaires pour améliorer la couverture des langues à faibles ressources ; un dossier de présentation de l'AAC, accompagné du corpus et de la documentation linguistique du présent mémoire, constitue une base de dépôt crédible auprès de ces équipes.
- Recours aux techniques d'extension de vocabulaire sans réentraînement complet : des méthodes désormais bien établies en traitement automatique du langage permettent d'ajouter de nouveaux tokens à un modèle déjà entraîné, par un ajustement localisé plutôt qu'un réentraînement intégral — une voie nettement moins coûteuse, mobilisable par un laboratoire universitaire ou une équipe indépendante, sans attendre la bonne volonté d'un grand fournisseur.

- Déploiement d'une couche de conversion en amont et en aval des modèles existants, dès aujourd'hui : en attendant qu'un tokeniseur natif AAC existe, le convertisseur bidirectionnel déjà développé (prototype technique associé à ce mémoire) permet de traduire automatiquement un texte AAC vers l'orthographe de 1979 avant de le soumettre à un modèle actuel, puis de reconvertir sa réponse en AAC — une solution de transition immédiatement opérationnelle, qui ne requiert l'accord d'aucun tiers.

5.7 Bénéfices attendus

Une fois ce protocole engagé et un volume suffisant de corpus AAC intégré aux cycles d'entraînement futurs, les bénéfices attendus se déclinent sur trois plans. Sur le plan économique, une tokenisation plus compacte et moins ambiguë réduit le nombre de tokens consommés par unité de texte, un facteur qui détermine directement le coût d'utilisation des interfaces de programmation facturées au token, ainsi que la quantité de texte exploitable dans la fenêtre de contexte limitée de tout modèle. Sur le plan qualitatif, la désambiguïsation entre créole et français au niveau du token même devrait améliorer la fiabilité des tâches de traduction automatique, de correction orthographique et de synthèse vocale spécifiquement pour le créole, en réduisant l'interférence représentationnelle décrite à la section 5.2. Sur le plan stratégique, enfin, disposer d'une orthographe dont la distinctivité graphique est reconnue par construction positionne le créole haïtien plus favorablement dans

l'écosystème mondial de l'intelligence artificielle, à un moment où la couverture linguistique des grands modèles devient un enjeu de souveraineté numérique à part entière pour les langues à faibles ressources.

BILAN DU CHAPITRE — La tokenisation n'est pas un détail technique périphérique : elle est aujourd'hui l'une des portes d'entrée déterminantes de toute langue dans l'écosystème de l'intelligence artificielle. L'AAC offre, par la distinctivité de ses trois monogrammes, une réponse structurelle au problème de conflation avec le français documenté dans ce chapitre — un bénéfice réel, mais différé, qui suppose un effort délibéré de constitution et de diffusion de corpus pour se concrétiser. Ce chapitre a proposé cinq leviers concrets pour engager cet effort dès aujourd'hui, sans attendre qu'il soit décidé par des tiers.

Conclusion générale

Synthèse des résultats majeurs

Ce mémoire s'est proposé de répondre à une problématique précise : dans quelle mesure une refonte rationalisée et atomique de l'alphabet du créole haïtien peut-elle optimiser ses performances technologiques, économiques et pédagogiques à l'ère de la mondialisation numérique, sans rompre la continuité institutionnelle établie par le décret du 28 septembre 1979 ? L'ensemble de la démonstration conduite au fil des cinq chapitres permet d'apporter à cette question une réponse argumentée et documentée.

Le premier chapitre a établi que la question orthographique du créole haïtien s'inscrit dans une trajectoire historique longue, depuis les transcriptions anarchiques de la période coloniale jusqu'à la consécration scientifique et institutionnelle de la réforme de 1979, en passant par la période de compétition féconde entre les systèmes McConnell-Laubach et Pressoir-Faublas. Cette mise en perspective historique a permis d'établir que la présente proposition ne constitue en aucune façon une rupture avec cet héritage, mais s'inscrit au contraire dans sa continuité directe.

Le deuxième chapitre a posé un diagnostic critique et documenté des limites structurelles de la graphie actuelle : la persistance de six digrammes et trigrammes fonctionnels en contradiction avec le principe de bi-univocité proclamé par le décret de 1979 lui-même ;

l'ambiguïté algorithmique que ces mêmes séquences introduisent dans les systèmes de traitement automatique du langage naturel ; et le cas emblématique de la voyelle fantôme u, dépourvue d'existence phonologique autonome dans le système créole.

Et face à ce diagnostic, le troisième chapitre propose une réponse systémique : l'Alphabet Atomique Créole, fondé sur le principe de bi-univocité totale et sur trois principes de conception inviolables, parcimonie de graphèmes, rétrocompatibilité visuelle, faisabilité technique immédiate. Il a d'abord posé une distinction théorique centrale, celle de l'alphabet atomique : une lettre irréductible représente un son de base sous une forme de base, tandis qu'une combinaison (nasale ou accentuée), se déduit d'une règle de composition régulière et ne doit pas être comptée comme une lettre distincte. Appliquée à l'inventaire pédagogique de 1979, cette distinction ramène l'alphabet nominal de trente-deux à vingt-quatre lettres, sans qu'aucun mot ne change d'orthographe : an, en, on, à, è et ò continuent de s'écrire à l'identique, tandis que ch, ou, oun et ng sont remplacés par les monogrammes š, ǒ et ŋ, exclusivement puisés dans le standard Unicode déjà existant. Le cas du son nasal /ũ/, autrefois noté par le trigramme oun, ne requiert lui-même aucun symbole distinct, puisqu'il découle automatiquement de l'application à ǒ de la même règle de composition n déjà en vigueur pour an, en et on. Ce chapitre a également détaillé le protocole concret de normalisation numérique nécessaire à son implémentation : standardisation des claviers, encodage Unicode déjà satisfait,

entraînement des modèles d'intelligence artificielle, et feuille de route de déploiement en quatre phases échelonnées sur environ deux années.

Il nous restait à chiffrer cette réforme, C'est l'objet du quatrième chapitre, qui quantifie les impacts attendus de cette réforme sur un corpus littéraire de référence (un extrait de René Depestre, dont l'analyse a révélé un gain net de neuf virgule trois pour cent en nombre de caractères), et sur des projections à l'échelle éditoriale nationale, révélant des économies significatives en matière d'impression, de consommation de papier et d'émissions de dioxyde de carbone. Ce même chapitre a établi, sur la base de la recherche en neurosciences de la lecture et en psychologie de l'écriture manuscrite, que la charge mnémotechnique nouvelle se limite strictement aux quatre séquences réellement opaques de l'orthographe actuelle, tout en démontrant la viabilité économique et méthodologique d'une transition progressive, réversible et pratiquement gratuite sur le plan technique.

Enfin, Le cinquième chapitre, a examiné un enjeu contemporain distinct de l'économie scripturale traditionnelle : le traitement du créole par les grands modèles de langage. Il a établi, sur le plan technique, que le partage graphique entre le créole et le français au niveau des séquences ch, ou, an, en et on expose l'orthographe actuelle à une conflation représentationnelle documentée dans la littérature scientifique consacrée à l'équité tokenistique entre langues,

et que les trois monogrammes de l'AAC, par leur distinctivité graphique absolue vis-à-vis du français, offrent une réponse structurelle à ce problème précis — un bénéfice réel mais différé, conditionné à un effort délibéré de constitution et de diffusion de corpus, pour lequel ce chapitre a proposé un protocole concret en cinq leviers.

Les trois hypothèses formulées en introduction se trouvent ainsi confirmées par l'ensemble de cette démonstration : la présence de séquences opaques crée une surcharge cognitive et une ambiguïté algorithmique mesurables ; un alphabet atomique rétrocompatible et techniquement réalisable peut être conçu pour y remédier, en intervenant strictement là où le système est réellement défaillant et nulle part ailleurs ; et les gains associés à son adoption, de l'ordre de 9 à 13 % en économie de graphèmes, demeurent substantiels au regard d'un coût de transition rendu quasi nul par le choix délibéré de graphèmes déjà standardisés.

Limites de la recherche et perspectives d'avenir

La présente recherche comporte des limites méthodologiques qu'il convient d'assumer avec la rigueur scientifique requise. L'analyse quantitative du chapitre IV repose sur un corpus certes représentatif mais unique ; une validation statistique plus robuste supposerait la constitution d'un corpus élargi, couvrant plusieurs registres de langue (littéraire, journalistique, administratif, conversationnel), et plusieurs variétés régionales du créole haïtien,

afin de vérifier la stabilité du gain de neuf à treize pour cent annoncé dans des conditions d'usage réellement diversifiées. De même, les estimations relatives à la réduction de la charge mnémotechnique et au coût cognitif du tracé manuscrit, bien que fondées sur une littérature scientifique établie en neurosciences de la lecture et en psychologie de l'écriture, gagneraient à être confirmées par une étude expérimentale directe conduite auprès d'apprenants haïtiens, dans le cadre précis de la phase pilote décrite au chapitre III.

Le choix délibéré de fonder l'AAC exclusivement sur des graphèmes déjà standardisés (š, ۆ, ȳ) réduit très significativement le risque technique de la proposition par rapport à une création typographique originale, mais ne dispense pas d'une validation empirique de son adoption effective : la lisibilité comparée de š et de ch en conditions réelles de lecture rapide, l'aisance de frappe du couple š/ۆ sur clavier mobile en usage prolongé, et la vitesse d'appropriation des trois substitutions par de jeunes apprenants restent des questions empiriques ouvertes, que seule la phase pilote de six mois recommandée au chapitre III permettra de trancher avec la rigueur requise avant toute généralisation.

Ces limites, loin de fragiliser la proposition centrale de ce mémoire, en circonscrivent au contraire précisément le statut : celui d'une hypothèse de travail rigoureusement argumentée et documentée, soumise à l'Académie du Créole Haïtien pour discussion, amendement et validation empirique progressive, et non

celui d'une réforme achevée et prête à une application immédiate et irréversible. C'est dans cet esprit de dialogue scientifique et institutionnel que ce mémoire est présenté.

Les perspectives ouvertes par ce travail sont de trois ordres. Sur le plan scientifique, elles appellent la conduite d'études expérimentales complémentaires en psycholinguistique de la lecture et en didactique de l'écriture, en partenariat avec les institutions universitaires haïtiennes, au premier rang desquelles l'Université d'État d'Haïti. Sur le plan technique, elles appellent la publication effective des dispositions clavier CLDR et des outils de conversion automatique en licence libre, seule condition matérielle restante d'une validation d'usage réelle, l'absence de développement typographique constituant précisément l'un des acquis majeurs de la présente proposition. Sur le plan institutionnel, enfin, elles appellent l'ouverture d'un dialogue formel avec l'Académie du Créole Haïtien, seule instance légalement mandatée pour statuer sur toute évolution de la norme orthographique officielle du créole haïtien, à qui ce mémoire est respectueusement soumis comme contribution à la réflexion collective sur l'avenir graphique de la langue nationale.

En 1928, la République de Turquie a remplacé l'alphabet arabe par l'alphabet latin en l'espace de six semaines, ouvrant l'accès à l'éducation formelle à des millions de citoyens. En 1972, le gouvernement norvégien a unifié deux variantes écrites de sa langue pour consolider l'identité nationale. En 1979, la République d'Haïti a accompli un acte de souveraineté linguistique remarquable en dotant le créole d'un alphabet phonologique rigoureux. Ces réformes ont en commun

d'avoir été des actes politiques délibérés, portés par une conviction partagée : la forme de l'écriture n'est jamais neutre, elle façonne l'accès au savoir, à la pleine citoyenneté et à la dignité humaine.

L'Alphabet Atomique Créole s'inscrit dans cette tradition historique avec la pleine conscience de sa propre modestie. Il ne prétend pas révolutionner la langue créole ; il prétend simplement lui rendre la promesse que l'alphabet de 1979 avait formulée avec clarté, et que les outils technologiques de l'époque ne permettaient pas encore d'honorer intégralement. Un son, un signe, sans exception : cette promesse tenue, dans la langue de onze millions de personnes, ne serait pas seulement un acte de souveraineté graphique. Elle serait un acte de justice envers toutes les générations d'apprenants haïtiens qui, depuis 1979, ont dû mémoriser deux lettres là où une seule aurait suffi.

Références bibliographiques

Akademi Kreyòl Ayisyen (2017). Premye rezolisyon sou òtograf lang kreyòl ayisyen. Port-au-Prince, 1er juin 2017.

Alamargot, D. & Fayol, M. (2009). Modelling the development of written composition. In R. Beard, D. Myhill, J. Riley & M. Nystrand (dir.), *The SAGE Handbook of Writing Development*. Londres : SAGE Publications.

Constitution de la République d'Haïti (1987). Articles 5 et 40 relatifs au statut officiel du créole et du français.

Dehaene, S. (2007). *Les neurones de la lecture*. Paris : Odile Jacob.

Ehri, L. C. (2005). Learning to read words: Theory, findings, and issues. *Scientific Studies of Reading*, 9(2), 167-188.

Faublas, J. J. & Pressoir, C. F. (1947). *Système orthographique révisé du créole haïtien*.

Gourdet, F. (2022). Estanda grafi kreyòl Ayiti : Pwopozisyon. *Rechèch Etid Kreyòl*, 1(1), 163-203.

Laubach, F. C. & McConnell, H. O. (1940). *Premier système graphique cohérent pour le créole haïtien*.

Ministère de l'Éducation Nationale d'Haïti (1979). Décret du 28 septembre 1979 instituant l'alphabet officiel du créole haïtien.

Orife, I. (2018) et travaux ultérieurs sur la restauration automatique des diacritiques en langue yoruba (Orife et al., 2020 ; Asahiah, Odejobi et al.) — traitement automatique du langage et omission des caractères accentués par point souscrit.

Pan-Nigerian Alphabet (National Language Centre of Nigeria, années 1980) — norme orthographique panafricaine incluant le graphème ɛ (U+1E62/U+1E63) pour le phonème /ɛ /.

Petrov, A., La Malfa, E., Torr, P. H. S. & Bibi, A. (2023). Language Model Tokenizers Introduce Unfairness Between Languages. *Advances in Neural Information Processing Systems (NeurIPS 2023)*.

Rayner, K., Foorman, B. R., Perfetti, C. A., Pesetsky, D. & Seidenberg, M. S. (2001). How psychological science informs the teaching of reading. *Psychological Science in the Public Interest*, 2(2), 31-74.

République d'Haïti (2014). Loi du 6 avril 2014 portant création de l'Académie du Créole Haïtien (Akademi Kreyòl Ayisyen).

Unicode Consortium. The Unicode Standard, blocs Latin Extended-A et Latin Extended-B.

Vernet, P. et al. Travaux de la commission linguistique haïtienne préparatoire à la réforme orthographique de 1979.

Zesiger, P. (1995). *Écrire : approches cognitive, neuropsychologique et développementale*. Paris : Presses Universitaires de France.

Annexe — Glossaire des termes techniques

Ce glossaire rassemble, pour la commodité du lecteur non spécialiste, les principaux termes techniques employés dans le présent mémoire.

Bi-univocité — Principe selon lequel chaque son (phonème) d'une langue correspond à un seul symbole graphique (graphème), et réciproquement, sans exception ni ambiguïté.

Alphabet atomique — Alphabet dont chaque lettre représente un son de base unique, sous une forme de base unique, et qui est elle-même irréductible à toute décomposition ultérieure. N'exclut pas les combinaisons de lettres, mais exige qu'elles soient reconnues comme telles plutôt que comptées comme des lettres distinctes.

Aksan fòs — Nom créole de l'accent grave, seul signe diacritique d'accentuation du créole haïtien, appliqué aux voyelles a, e, o pour en marquer le timbre ouvert (â, è, ò).

Digramme — Séquence de deux lettres encodant un seul son. Exemple : ch pour le son /ʃ /.

Trigramme — Séquence de trois lettres encodant un seul son. Exemple : ou pour le son /ũ/.

Monogramme — Lettre unique, éventuellement modifiée par un diacritique, encodant un seul son.

Graphème — Unité minimale du système d'écriture représentant, à elle seule ou en combinaison, un son de la langue.

Phonème — Unité sonore minimale distinctive d'une langue, transcrite entre barres obliques selon la convention de l'alphabet phonétique international (API), par exemple /ʃ /.

Diacritique — Signe graphique ajouté à une lettre pour en modifier la valeur phonétique, tel que le tilde (~) ou la brève (˘).

Ligature — Caractère unique résultant de la fusion graphique de deux lettres distinctes, à l'instar de æ, œ ou ß dans la tradition latine.

Tokenisation — Étape des algorithmes de traitement automatique du langage naturel consistant à découper un texte en unités lexicales (tokens) analysables par la machine.

Byte Pair Encoding (BPE) — Algorithme de tokenisation par apprentissage statistique, fusionnant itérativement les paires de symboles les plus fréquentes d'un corpus d'entraînement pour construire un vocabulaire de tokens de taille fixe.

Fertilité tokenistique — Nombre moyen de tokens nécessaires pour représenter un mot ou un texte donné dans une langue ; une fertilité élevée indique un traitement moins efficace de cette langue par un modèle donné.

Unicode — Norme internationale d'encodage informatique des caractères, garantissant qu'un même caractère est représenté et affiché de façon identique sur tout système compatible.

ISO 15924 — Norme internationale de codification des systèmes d'écriture (scripts), distincte de l'encodage des caractères eux-mêmes.

CLDR (Common Locale Data Repository) — Référentiel international de données linguistiques et régionales maintenu par le Consortium Unicode, notamment utilisé pour la définition des dispositions de clavier.

Zone d'usage privé (Private Use Area) — Plage de codes Unicode réservée à des usages non standardisés internationalement, employée à titre transitoire pour des caractères en attente de normalisation officielle.

Annexe — Inventaire phonologique complet en Alphabet Phonétique International

Cette annexe rassemble, en un tableau unique par catégorie, l'intégralité de l'inventaire phonologique du créole haïtien tel qu'analysé dans le présent mémoire, avec sa transcription en Alphabet Phonétique International (API), sa notation dans l'orthographe officielle de 1979 et sa notation dans l'AAC. Elle complète l'index Unicode (annexe précédente), centré sur les graphèmes, en offrant une vue centrée sur les phonèmes eux-mêmes — utile en particulier pour toute vérification linguistique indépendante de la correspondance son/graphème proposée par ce mémoire.

POURQUOI 30 PHONÈMES ICI, ET NON 24 OU 32 ? — Ce mémoire cite trois comptes distincts, répondant chacun à une question différente. Le chiffre de 32 (chapitre II, section 2.4) répond à la question « combien de lettres l'enseignement traditionnel de 1979 présente-t-il ? » — un compte nominal et pédagogique qui additionne à tort des combinaisons (ch, oun, an...) et de véritables unités irréductibles. Le chiffre de 24 (chapitre III, section 3.1.4) répond à « combien de lettres irréductibles suffisent, à l'écrit, à engendrer tous les mots du créole ? »

— un compte de graphèmes, celui de l'alphabet atomique de l'AAC. Le chiffre de 30, présenté dans cette annexe, répond à une troisième question, purement phonologique : « combien de sons distincts la langue parlée possède-t-elle réellement ? », indépendamment de la façon dont on choisit de les écrire. Les quatre voyelles nasales, par exemple, sont des

sons pleinement distincts de leurs équivalents oraux (comptées à ce titre parmi les 30 phonèmes), mais l'AAC, comme l'orthographe de 1979 avant lui, choisit de ne pas leur attribuer de lettre propre à l'écrit : elles s'écrivent par une règle de composition (voyelle + n), ce qui explique leur absence des 24 lettres atomiques sans contredire leur statut de phonèmes réels. À l'inverse, à n'est pas un son distinct de a, contrairement à è et ò, qui sont bien des phonèmes distincts de e et o, ce qui explique que le compte phonémique ne soit ni un multiple simple ni un sous-ensemble direct du compte de graphèmes. Ces trois chiffres coexistent donc légitimement : ils ne mesurent pas la même chose.

Voyelles

Le créole haïtien distingue sept timbres vocaliques oraux et quatre voyelles nasales, soit onze unités vocaliques phonémiques au total.

API	Type	1979	AAC	Exemple (1979 → AAC)
/a/	Orale	A	a	lapli → lapli
/ɛ/	Orale	E	è	lanmè → lanmè
/e/	Orale	E	e	kle → kle
/i/	Orale	I	i	lapli → lapli
/ɔ/	Orale	O	ò	lekòl → lekòl
/o/	Orale	O	o	solèy → solèy
/u/	Orale	Ou	ö	pou → pö
/ã/	Nasale	An	an	manman → manman
/ẽ/	Nasale	En	en	mwen → mwen
/õ/	Nasale	On	on	tonbe → tonbe
/ũ/	Nasale	Oun	ön	moun → mön

Consonnes

Dix-sept consonnes composent l'inventaire consonantique du créole haïtien tel que retenu par l'AAC.

API	Mode / lieu d'articulation	1979	AAC	Exemple
/b/	Occlusive bilabiale voisée	b	B	bèl
/d/	Occlusive dentale voisée	d	D	dlo
/f/	Fricative labiodentale sourde	f	F	fanm
/g/	Occlusive vélaire voisée	g	G	gwo
/ʒ/	Fricative postalvéolaire voisée	j	J	jou → jö
/k/	Occlusive vélaire sourde	k	K	kay
/l/	Latérale alvéolaire	l	L	lang → laŋ
/m/	Nasale bilabiale	m	M	manje
/n/	Nasale alvéolaire	n	N	nou → nõ
/ɲ/	Nasale palatale	ng	Ɔ	lang → laŋ
/p/	Occlusive bilabiale sourde	p	P	pou → pö
/ʁ/	Fricative uvulaire voisée	r	R	rat
/s/	Fricative alvéolaire sourde	s	S	san
/ʃ/	Fricative postalvéolaire sourde	ch	Š	chèz → šèz
/t/	Occlusive dentale sourde	t	T	tè
/v/	Fricative labiodentale voisée	v	V	vle
/z/	Fricative alvéolaire voisée	z	Z	zwazo

Semi-voyelles et séquence particulière

API	Description	1979	AAC	Exemple
/w/	Semi-voyelle labio-vélaire	w	W	wozo
/j/	Semi-voyelle palatale	y	Y	yo
/ɥi/ ~ /jw/	Séquence semi-voyelle + voyelle	ui	Wi	kuit → kwit

Au total, l'inventaire phonémique du créole haïtien tel que décrit dans ce mémoire comprend onze voyelles (sept orales, quatre nasales), dix-sept consonnes et deux semi-voyelles, soit trente phonèmes distincts. Ce chiffre, à ne pas confondre avec le compte de vingt-quatre lettres atomiques (chapitre III, section 3.1.4), inclut les quatre voyelles nasales et exclut les voyelles accentuées à, è, ò — celles-ci n'étant pas des phonèmes supplémentaires mais des réalisations des phonèmes /a/, /ɛ / et /ɔ / déjà comptés ci-dessus, notées par un signe diacritique distinctif dans le contexte précis exposé à la section 3.1.2.

Index — Les vingt-quatre lettres atomiques de l'AAC et leurs codepoints Unicode

Cet index recense, par ordre alphabétique, l'intégralité des vingt-quatre lettres de l'alphabet atomique défini au chapitre III (section 3.1.4), avec leur valeur phonétique de référence en alphabet phonétique international, leur codepoint Unicode exact en minuscule et en majuscule, et leur catégorie. Les vingt et une lettres non annotées sont des caractères ASCII de base (bloc Unicode Basic Latin), disponibles nativement sur tout système depuis l'origine du codage informatique des caractères. Les trois lettres marquées « remplace » sont les seuls graphèmes propres à l'AAC, tous trois puisés dans le bloc Unicode Latin Extended-A, disponible en standard sur les systèmes d'exploitation contemporains.

Lettre	API	Minuscule	Majuscule	Catégorie
a	/a/	a — U+0061	A — U+0041	Voyelle
b	/b/	b — U+0062	B — U+0042	Consonne
d	/d/	d — U+0064	D — U+0044	Consonne
e	/e/, /ɛ /	e — U+0065	E — U+0045	Voyelle
f	/f/	f — U+0066	F — U+0046	Consonne
g	/g/	g — U+0067	G — U+0047	Consonne
i	/i/	i — U+0069	I — U+0049	Voyelle
j	/ʒ /	j — U+006A	J — U+004A	Consonne
k	/k/	k — U+006B	K — U+004B	Consonne
l	/l/	l — U+006C	L — U+004C	Consonne
m	/m/	m — U+006D	M — U+004D	Consonne

Lettre	API	Minuscule	Majuscule	Catégorie
n	/n/	n — U+006E	N — U+004E	Consonne
ŋ	/ɲ/	ŋ — U+014B	Ɔ — U+014A	Consonne (remplace ng)
o	/o/, /ɔ/	o — U+006F	O — U+004F	Voyelle
ö	/u/	ö — U+014F	Ö — U+014E	Voyelle (remplace ou)
p	/p/	p — U+0070	P — U+0050	Consonne
r	/ʁ/	r — U+0072	R — U+0052	Consonne
s	/s/	s — U+0073	S — U+0053	Consonne
š	/ʃ/	š — U+0161	Š — U+0160	Consonne (remplace ch)
t	/t/	t — U+0074	T — U+0054	Consonne
v	/v/	v — U+0076	V — U+0056	Consonne
w	/w/	w — U+0077	W — U+0057	Semi-voyelle
y	/j/	y — U+0079	Y — U+0059	Semi-voyelle
z	/z/	z — U+007A	Z — U+005A	Consonne

Pour rappel, conformément au principe de parcimonie de graphèmes établi au chapitre III, les séquences an, en, on, à, è et ò ne figurent pas dans cet index en tant que lettres distinctes : elles sont des combinaisons régulières de lettres atomiques déjà répertoriées ci-dessus (respectivement a/e/o suivi de n, ou a/e/o affecté de l'aksan fòs), et non des unités supplémentaires de l'alphabet.

Index thématique — Navigation par concept

Cet index recense, par ordre alphabétique de concept, les principales notions abordées dans ce mémoire, avec renvoi aux sections concernées. Les renvois utilisent la numérotation des chapitres et sections plutôt que des numéros de page, ceux-ci n'étant pas stables selon le format d'édition (Letter ou 6×9 po) dans lequel ce document est produit.

Aksan fòs (accent grave) — 3.1.2, 3.2, glossaire

Alphabet atomique (définition) — 3.1.1, glossaire

Alphabet Atomique Créole (AAC), présentation générale —
Introduction, Chapitre III

Alphabets africains (swahili, lingala, wolof, éwé, fon, yoruba) — 3.4.3

Bernard, Joseph C. (décret de 1979) — 1.3

Bi-univocité (principe de) — Introduction, 3.1, glossaire

BPE (Byte Pair Encoding) — 5.1, glossaire

Claviers, dispositions CLDR — 3.3.1, 3.3.4

Combinaison phonotactique et diacritique — 3.2

Corpus Depestre (analyse quantitative) — 4.1.2

Digrammes et trigrammes (anomalie) — 2.1, glossaire

Fertilité tokenistique — 5.3, glossaire

Gourdet, Frantz (proposition linéariste de 2022) — 3.4.3, 3.5

Grammaire créole (périmètre de la réforme) — 3.6

h (disparition de la lettre) — 3.1.3

Inflation nominale de l'alphabet (32 lettres) — 2.4, 3.1.1

- Ligature êh (alternative écartée)** — 3.4.1
- Mòn / moun (paire minimale)** — 3.2 (démonstration lexicale)
- Nasalisation (règle par défaut et exception)** — 3.1.2, 3.2
- ŋ (eng, remplace ng)** — 3.1.4, index Unicode
- ö (o à brève, remplace ou)** — 3.1.4, index Unicode
- Phase de déploiement (feuille de route)** — 3.3.4
- Pressoir-Faublas (système de 1947)** — 1.2.2
- Résolution AKA 2017** — 1.3, 3.5
- š (s caron, remplace ch)** — 3.1.4, 3.4.1, 3.4.3, index Unicode
- Tilde de nasalité (alternative écartée)** — 3.4.2
- Tokenisation (mécanisme technique)** — 5.1
- u (voyelle fantôme)** — 2.3
- ui → wi (correction)** — 2.3, 3.1
- Unicode (blocs et codepoints)** — 3.3.2, index Unicode
- Vernet, Pierre (commission linguistique de 1979)** — 1.3
- Vietnamien, chữ Quốc ngữ (comparaison internationale)** — 1.4
- Yoruba (ṣ , point souscrit)** — 3.4.3

Synthèse finale — Le créole face aux grandes langues internationales

Ce tableau clôt le présent document en remplaçant l'AAC dans une perspective comparative volontairement plus large que celle du chapitre III : non plus seulement face aux systèmes graphiques concurrents du créole lui-même, mais face à trois langues de très large diffusion internationale, dont l'orthographe est réputée à des degrés très divers pour sa régularité ou son irrégularité. La colonne « correspondances irrégulières » recense les cas où un même son s'écrit de plusieurs façons différentes selon les mots, sans qu'aucune règle générale ne permette de prédire laquelle s'applique — c'est-à-dire les cas que le locuteur ou l'algorithme doit mémoriser au cas par cas, faute de règle.

Langue / système	Phonèmes	Graphèmes nominaux	Correspondances irrégulières	Nouveaux symboles requis
Anglais	≈ 44	26	Très nombreuses — ex. /ʃ / s'écrit sh, ti, ci, ch, s ou ss selon les mots (nation, special, machine, sugar, mission...)	Non résolu à ce jour
Français	≈ 36	26 (+ diacritiques)	Nombreuses — ex. /o/ s'écrit o, ô, au ou eau selon les mots (mot, tôt, faux, eau)	Non résolu à ce jour
Espagnol	≈ 24	27	Très rares — essentiellement b/v (confondus à l'oral) et h muet	Quasi résolu nativement
Créole — Officiel 1979	30	32	5 séquences opaques : ch, ou, oun, ng, ui (chapitre II)	—

Langue / système	Phonèmes	Graphèmes nominaux	Correspondances irrégulières	Nouveaux symboles requis
Créole — Gourdet (2022)	30	Non réduit	0	6 symboles (c, u, ü, ä, ë, ö) + yw
Créole — AAC (présente proposition)	30	24	0	3 symboles (š, ō, ŋ)

CE QUE CE TABLEAU DÉMONTRE — L'anglais et le français, deux des langues les plus enseignées et les plus diffusées au monde, conservent à ce jour des dizaines de correspondances son/signe irrégulières que nul projet de réforme d'envergure n'est aujourd'hui en mesure de corriger, tant le poids de leurs corpus écrits historiques rend toute intervention massive impraticable. L'espagnol, souvent cité en linguistique comme l'une des orthographe les plus phonémiques parmi les grandes langues internationales, n'atteint pas non plus la régularité totale : la confusion b/v et le h muet y demeurent deux exceptions résiduelles. Le créole haïtien, doté de l'AAC, atteint un objectif qu'aucune de ces trois langues n'a pleinement réalisé : l'élimination complète de toute correspondance son/signe irrégulière — et il l'atteint avec un coût d'intervention, trois symboles nouveaux puisés dans le standard Unicode existant, inférieur à celui de toute réforme comparable recensée dans ce mémoire, y compris la proposition Gourdet (2022), qui atteint certes le même objectif de régularité totale mais au prix du double de symboles nouveaux. Ramené à l'échelle du créole, ce résultat n'est pas un raffinement cosmétique : il est ce qu'aucune langue de diffusion mondiale comparable n'offre aujourd'hui à ses locuteurs — une écriture entièrement, et non presque entièrement, prévisible.

À propos de l'auteur

Haricot Lincoln Compère est ingénieur en informatique et locuteur natif du créole haïtien. Titulaire d'une licence en Sciences Informatiques de l'Université d'État d'Haïti (Campus Henry Christophe de Limonade, mention Très Bien), travaillé dans les systèmes d'information d'entreprise (SAP), développement de système de gestion et les infrastructures IT en Haïti. Ce livre est né de la conviction que la rigueur technique — encodage, normalisation, traitement automatique du langage — a autant à apporter à l'avenir de la langue créole que la recherche linguistique traditionnelle, et que les deux gagnent à dialoguer plutôt qu'à s'ignorer.

Le prototype technique associé à cet ouvrage (convertisseur orthographique, démonstration interactive, outils de conversion) est disponible en accès libre sur GitHub, sous licence MIT.

lincolncompere@gmail.com · github.com/lincoln509/aac